

COURSE 4

module 1

1. hands-on lab: writing your first python code => menulis kode Python dasar, mencetak pesan ke layar menggunakan fungsi print(), menambahkan komentar di dalam baris kode menggunakan tanda pagar (#), serta melakukan operasi aritmatika sederhana untuk menghitung nilai variabel.
2. hands-on lab: working with types in python => mengenali berbagai tipe data dalam Python, menggunakan fungsi type() untuk mengecek jenis data (seperti hasil perbandingan boolean), melakukan konversi tipe data (type casting) dari string ke integer dan float, serta mengubah angka atau karakter menjadi tipe string menggunakan fungsi str().
3. hands-on lab: working with variables and expressions in python => melakukan operasi matematika menggunakan ekspresi, menyimpan hasil perhitungan ke dalam variabel, memahami urutan operasi (tanda kurung dan perkalian), serta menggabungkan beberapa variabel untuk menghasilkan nilai baru melalui operasi penjumlahan.
4. hands-on lab: string operations => memanipulasi teks menggunakan modul re (Regular Expressions), mencari keberadaan digit menggunakan fungsi search(), mengganti kata tertentu dalam kalimat menggunakan fungsi sub(), serta menemukan semua kemunculan pola karakter spesifik menggunakan fungsi findall().

module 2

1. hands-on lab: lists => membuat shopping list, menyimpan item ke dalam list, menambah item ke dalam list, print first, last, entire, print item penting yg perlu dibeli, ubah item, delete item yg tidak diperlukan, print shopping list.
2. hands-on lab: tuples => melakukan operasi dasar tuple, mengakses data melalui indexing, memotong bagian data dengan slicing, dan mengurutkan elemen menggunakan fungsi sorted() untuk menghasilkan list baru yang teratur.
3. hands-on lab: dictionaries => mengecek keberadaan kunci (key) dalam inventaris menggunakan operator in, menghapus data yang tidak diperlukan menggunakan keyword del, melakukan pembersihan data spesifik (tahun rilis produk), dan mengelola struktur data pasangan kunci-nilai (key-value pairs).
4. hands-on lab: sets => bekerja dengan struktur data set untuk menyimpan elemen unik, menggabungkan dua buah set menggunakan operasi union(), mengecek hubungan antar

himpunan menggunakan fungsi `issubset()`, serta memahami logika operasi himpunan dalam Python.

module 3

1. hands-on lab: conditions and branching => menggunakan operator perbandingan untuk menghasilkan nilai Boolean, menerapkan logika percabangan (branching) untuk mengontrol alur program, serta memahami penggunaan operator logika guna mengevaluasi berbagai kondisi pernyataan dalam Python.
2. hands-on lab: loops => menggunakan pernyataan pengulangan for loop dan while loop, menerapkan fungsi `range()` untuk menghasilkan deret angka, serta mengontrol alur pengulangan menggunakan pernyataan `continue` untuk melewati iterasi tertentu dan `break` untuk menghentikan pengulangan berdasarkan kondisi spesifik.
3. hands-on lab: functions => mendefinisikan fungsi kustom menggunakan keyword `def`, memahami interaksi antara fungsi dan variabel, memproses string menjadi daftar kata menggunakan `split()`, serta menggunakan struktur data dictionary di dalam fungsi untuk menghitung frekuensi kemunculan kata spesifik.
4. hands-on lab: exception handling => memahami konsep eksepsi dalam Python, mengimplementasikan blok `try-except` untuk menangani kesalahan saat program berjalan, menggunakan kelas generic `Exception` untuk menangkap berbagai jenis error, serta membuat fungsi yang aman dari kegagalan kalkulasi (seperti pembagian dengan nol) untuk menjaga stabilitas program.
5. hands-on lab: classes and objects in python => memahami konsep pemrograman berorientasi objek (OOP), mendefinisikan kelas (class) beserta atribut dan metodenya, menggunakan fungsi `__init__` untuk inisialisasi data, membuat objek dari suatu kelas, serta memanggil metode untuk memodifikasi dan menampilkan properti objek.
6. practice lab => menerapkan seluruh konsep dasar Python yang telah dipelajari dalam skenario praktis, mengintegrasikan penggunaan tipe data, struktur kontrol (loop dan kondisi), fungsi, serta penanganan kesalahan (exception handling) untuk menyelesaikan tantangan pemrograman yang komprehensif.

module 4

1. hands-on lab: reading files python => membaca file teks menggunakan pustaka Python, membuka file dengan pernyataan `with open`, mengekstrak isi file ke dalam bentuk list

menggunakan metode `readlines()`, serta mengakses baris spesifik dalam file melalui teknik indexing.

2. hands-on lab: write and save files in python => menulis dan menyimpan data ke dalam file teks, menggunakan mode `r+` (baca/tulis) dan `a+` (tambah/baca), mengelola posisi kursor file dengan `seek()`, menyaring data anggota aktif dan tidak aktif menggunakan list comprehension, serta memperbarui isi file secara otomatis dengan metode `write()` dan `truncate()`.
3. hands-on lab: practice lab: selecting data in a dataframe => menggunakan pustaka Pandas untuk membuat DataFrame dan Series, mengakses lokasi data spesifik menggunakan fungsi `loc()` (berbasis label) dan `iloc()` (berbasis indeks numerik), serta menerapkan teknik slicing untuk mengambil rentang baris dan kolom tertentu dari sekumpulan data.
4. hands-on lab: loading data with pandas => menggunakan pustaka Pandas untuk memuat dan melihat data, mengakses kolom tertentu dalam bentuk DataFrame, mengambil nilai spesifik menggunakan koordinat baris dan kolom dengan `iloc[]`, mengubah indeks numerik menjadi indeks karakter, serta melakukan seleksi data berbasis label menggunakan fungsi `loc[]`.
5. hands-on lab: 1d numpy in python => mengimpor dan menggunakan pustaka NumPy, membuat array satu dimensi (1D), melakukan operasi vektor seperti penjumlahan dan perkalian skalar, menggunakan fungsi universal untuk kalkulasi matematis cepat, serta menerapkan teknik indexing dan slicing pada data numerik dalam format array.
6. hands-on lab: 2d numpy in python => mengimpor pustaka NumPy untuk membuat array dua dimensi (matriks), mengakses elemen menggunakan indeks baris dan kolom, melakukan operasi aritmatika pada matriks, serta menerapkan perkalian matriks menggunakan fungsi perkalian titik (dot product) untuk menyelesaikan kalkulasi numerik yang kompleks.

module 5

1. hands-on lab: introduction to api => memahami peran API sebagai jembatan komunikasi antar perangkat lunak, menggunakan pustaka Pandas sebagai API lokal untuk manipulasi data, serta berinteraksi dengan REST API (menggunakan `nba_api`) untuk mengambil data pihak ketiga melalui permintaan HTTP guna menganalisis performa tim olahraga berdasarkan statistik pertandingan.

2. hands-on lab: http and requests => memahami protokol komunikasi antara client (browser) dan server, membedah struktur URL (Scheme, Base URL, Route), melakukan permintaan data menggunakan metode GET dan mengirim data melalui body dengan metode POST, serta menggunakan pustaka Requests di Python untuk menangani respons HTTP, kode status (seperti 200 OK atau 404), dan mengunduh konten multimedia atau teks secara terprogram.
3. hands-on lab: api examples => mempraktikkan penggunaan berbagai jenis API publik seperti RandomUser API untuk menghasilkan data pengguna acak, Fruityvice API untuk mendapatkan informasi nutrisi buah, dan Open-Joke-API untuk mengambil konten hiburan, serta mendemonstrasikan cara mengonversi data JSON hasil API menjadi struktur Pandas DataFrame untuk keperluan manipulasi dan pembersihan data.
4. hands-on lab: web scraping => mengekstraksi data dari halaman web menggunakan pustaka BeautifulSoup dan Requests, memahami struktur dokumen HTML seperti tags, attributes, dan nested elements, serta melakukan pencarian data spesifik menggunakan metode find() dan find_all() untuk mengubah informasi dari situs web menjadi format data terstruktur seperti tabel atau berkas CSV.
5. hands-on lab: working with different file formats => memproses berbagai format file data (seperti CSV, JSON, atau Excel) ke dalam Python, melakukan eksplorasi data menggunakan pustaka Pandas, serta memvisualisasikan proporsi data kategori (seperti status kesehatan) menggunakan Matplotlib dan Seaborn melalui diagram lingkaran (pie chart) untuk mendapatkan wawasan statistik yang mudah dipahami.
6. practice project: gdp data extraction and processing => mengintegrasikan kemampuan pemrograman Python untuk melakukan ekstraksi data ekonomi (PDB) dari situs web melalui teknik web scraping, memproses data mentah menggunakan pustaka Pandas dan NumPy untuk pembersihan dan transformasi, serta menyimpan hasil akhir analisis ke dalam format penyimpanan permanen seperti berkas CSV agar dapat digunakan untuk pelaporan atau analisis lanjutan.

COURSE 5

Module 1

1. hands-on lab: web scraping => mempelajari teknik pengambilan data otomatis dari situs web menggunakan pustaka BeautifulSoup dan Requests, menavigasi struktur

dokumen HTML melalui tags dan attributes, serta mengekstraksi informasi spesifik dari tabel atau daftar untuk dikonversi menjadi dataset terstruktur yang siap dianalisis.

2. hands-on lab: extracting stock data using a python library => menggunakan pustaka `yfinance` untuk mengambil data historis pasar saham secara real-time, mengekstrak informasi harga (Open, High, Low, Close) dan volume perdagangan ke dalam Pandas DataFrame, serta mempraktikkan teknik manipulasi data seperti fungsi `.history()` untuk cakupan waktu maksimal dan fungsi `.head()` untuk mengisolasi catatan transaksi pada hari pertama perdagangan.
3. hands-on lab: extracting stock data using a web scraping => melakukan pengambilan data harga saham Amazon secara manual dari halaman web (seperti Yahoo Finance) menggunakan teknik scraping alih-alih API, memarsing struktur HTML untuk mengekstrak data tabel historis, serta menggunakan pustaka Pandas untuk membersihkan data, menampilkan struktur kolom, dan mengakses nilai spesifik seperti harga pembukaan (Open) pada baris terakhir melalui fungsi `.iloc[]`.

Module 2

1. hands-on lab: extracting and visualizing stock data => menggabungkan data harga saham historis dengan data pendapatan (revenue) perusahaan (seperti GameStop/GME), menggunakan fungsi kustom `make_graph` untuk membuat visualisasi komprehensif, serta menganalisis hubungan antara kinerja pasar saham dan metrik keuangan perusahaan dalam satu grafik interaktif untuk membantu pengambilan keputusan investasi.
2. final assignment: analyzing historical data =>
 - Penyelesaian Proyek & Submission (Q1): Melengkapi dan mengunggah Jupyter Notebook yang mendemonstrasikan pengerjaan bertahap, mulai dari menampilkan 5 baris pertama/terakhir dataframe (`tesla_data`, `tesla_revenue`, `gme_data`, `gme_revenue`) hingga menampilkan grafik visualisasi.
 - Teknis Web Scraping (Q2): Memahami jenis-jenis parser (seperti `html.parser`, `lxml`, atau `html5lib`) yang digunakan dalam pustaka BeautifulSoup untuk memproses data HTML.
 - Optimalisasi Data Deret Waktu (Q3 & Q4): Memahami urgensi konversi kolom 'Date' ke format datetime untuk analisis kronologis dan menerapkan teknik pembersihan data (string manipulation) untuk menghapus simbol \$ serta koma agar data bisa diolah secara numerik.

- Akurasi Ekstraksi Data (Q5 & Q6): Menemukan nilai spesifik pada baris tertentu, seperti nilai Revenue terakhir pada Tesla dan harga penutupan (Close price) perdana GameStop pada tanggal 13 Februari 2002.
- Interpretasi Grafik (Q7 & Q8): Melakukan analisis tren terhadap hasil visualisasi, khususnya mengamati pola pertumbuhan harga saham dan pendapatan Tesla (2018–2021) serta pengamatan kunci pada fenomena pergerakan data GameStop.

COURSE 6

Module 1

1. hands-on lab: simple select statements => mempelajari dasar-dasar bahasa kueri SQL menggunakan alat Datasette untuk berinteraksi dengan database Film Locations in San Francisco, dengan fokus pada pengambilan data dari tabel melalui perintah SELECT, memilih kolom spesifik, serta menerapkan filter data menggunakan klausa WHERE dan operator perbandingan.

Poin Utama Lab:

- Struktur Dasar SELECT: Memahami penggunaan tanda bintang (*) untuk mengambil seluruh kolom dan penyebutan nama kolom secara spesifik (misal: Title, Director) untuk hasil yang lebih ringkas.
 - Filtrasi Data dengan klausa WHERE:
 - Menggunakan operator >= untuk menyaring data berdasarkan ambang tahun tertentu (misal: film tahun 2001 ke atas).
 - Menggunakan operator <= untuk mengambil data historis (misal: film abad ke-20 atau sebelum tahun 2000).
 - Menggunakan operator <> atau != (Not Equal) untuk mengecualikan data spesifik, seperti menyaring film yang tidak ditulis oleh penulis tertentu.
 - Eksplorasi Atribut Database: Mengenali berbagai atribut data film seperti Title, ReleaseYear, Locations, hingga daftar pemeran (Actor1, Actor2, Actor3) dalam sebuah tabel relasional.
 - Praktik Kueri Mandiri: Mengasah kemampuan menulis sintaks SQL yang tepat untuk menjawab kebutuhan analisis data nyata, seperti mencari lokasi syuting dan fakta unik dari database film.
2. hands-on lab: count, distinct, limit => memperdalam penguasaan SQL untuk mengelola volume data dengan menggunakan fungsi agregat COUNT untuk menghitung jumlah

baris, klausa DISTINCT untuk mengeliminasi duplikasi data dan mengambil nilai unik, serta perintah LIMIT untuk membatasi jumlah baris yang ditampilkan, guna menghasilkan laporan data yang lebih ringkas dan spesifik.

Poin Utama Lab:

- Fungsi Agregat COUNT: * COUNT(*): Menghitung total seluruh baris dalam tabel.
 - COUNT(ColumnName): Menghitung jumlah entri pada kolom tertentu yang memenuhi kriteria (misal: jumlah lokasi film yang disutradarai Woody Allen).
 - Klausa DISTINCT untuk Data Unik:
 - Digunakan untuk mengambil daftar nilai yang tidak berulang (misal: daftar judul film unik agar satu film tidak muncul berkali-kali).
 - Dapat dikombinasikan dengan COUNT, seperti COUNT(DISTINCT ReleaseYear), untuk menghitung berapa banyak tahun perilisan yang berbeda dari sebuah rumah produksi.
 - Kontrol Baris dengan LIMIT & OFFSET:
 - LIMIT: Membatasi jumlah output (misal: hanya menampilkan 25 baris pertama).
 - OFFSET: Melewati sejumlah baris tertentu sebelum mulai mengambil data (misal: mengambil 15 baris setelah melewati 10 baris pertama).
 - Eksplorasi Database Kontekstual: Menerapkan kueri pada data Film Locations in San Francisco untuk menjawab kebutuhan praktis, seperti menghitung jumlah film yang syuting di lokasi spesifik (Russian Hill) atau membatasi daftar film yang rilis di tahun 2015.
3. hands-on lab: insert, update, delete => mempelajari perintah DML (Data Manipulation Language) untuk memanipulasi data di dalam tabel, yang mencakup penambahan baris baru dengan INSERT, mengubah informasi pada data yang sudah ada dengan UPDATE, serta menghapus baris data menggunakan perintah DELETE melalui alat Datasette pada database Instructor.

Poin Utama Lab:

- Menambah Data (INSERT):
 - INSERT INTO: Digunakan untuk memasukkan satu baris data secara spesifik ke kolom yang ditentukan.

- Multi-row Insert: Memungkinkan penginputan beberapa baris sekaligus dalam satu perintah dengan memisahkan kumpulan nilai menggunakan tanda koma.
- Mengubah Data (UPDATE):
 - SET: Digunakan untuk menentukan kolom mana yang akan diubah nilainya.
 - Pentingnya klausa WHERE: Digunakan untuk mengunci baris spesifik yang akan diubah (misal berdasarkan ins_id atau firstname) agar perubahan tidak berdampak pada seluruh baris di tabel.
- Menghapus Data (DELETE):
 - DELETE FROM: Perintah untuk menghapus rekaman data. Sama seperti UPDATE, klausa WHERE sangat krusial untuk memastikan hanya data tertentu (misal: ID nomor 6) yang terhapus dari sistem.
- Eksplorasi Atribut Database: Mempraktikkan kueri pada tabel Instructor yang memiliki atribut seperti ins_id, lastname, firstname, city, dan country.

Module 2

1. hands-on lab: create, alter, truncate, drop => mempelajari perintah DDL (Data Definition Language) untuk mendefinisikan dan mengelola struktur database menggunakan alat phpMyAdmin pada MySQL, yang mencakup pembuatan tabel baru dengan CREATE, modifikasi skema tabel dengan ALTER, pengosongan data tabel dengan TRUNCATE, serta penghapusan tabel secara permanen menggunakan perintah DROP.

Poin Utama Lab:

- Pembuatan Struktur (CREATE): Belajar membangun database dan tabel baru (seperti tabel PETSale dan PET) dengan menentukan tipe data yang sesuai seperti INTEGER, VARCHAR, DECIMAL, dan DATE.
- Modifikasi Tabel (ALTER):
 - ADD: Menambahkan kolom baru ke tabel yang sudah ada.
 - DROP COLUMN: Menghapus kolom yang tidak lagi diperlukan (misal: kolom PROFIT).
 - MODIFY: Mengubah tipe data atau kapasitas karakter suatu kolom (misal: mengubah CHAR menjadi VARCHAR).

- CHANGE/RENAME: Mengganti nama kolom tanpa merusak integritas data (misal: mengubah PET menjadi ANIMAL).
 - Penghapusan vs Pengosongan:
 - TRUNCATE: Menghapus seluruh isi data di dalam tabel tetapi tetap mempertahankan struktur tabelnya.
 - DROP: Menghapus tabel beserta seluruh strukturnya secara permanen dari database.
 - Manajemen Database via GUI: Mempraktikkan cara menjalankan kueri SQL melalui tab SQL di phpMyAdmin untuk manajemen data yang lebih efisien dibandingkan navigasi manual.
2. hands-on lab: create and load tables using sql scripts => mempelajari metode efisien dalam membangun struktur database yang kompleks dengan menjalankan berkas SQL Script untuk membuat banyak tabel sekaligus (PATIENTS, MEDICAL_HISTORY, dll.), serta menguasai teknik data ingestion dengan mengimpor data dalam jumlah besar langsung dari berkas CSV ke dalam tabel MySQL melalui antarmuka phpMyAdmin.

Poin Utama Lab:

- Efisiensi Scripting (SQL Scripts): Memahami bahwa kumpulan perintah DDL (seperti CREATE TABLE) dapat disusun dalam satu berkas .sql dan dijalankan secara berurutan untuk mengotomatiskan pembentukan skema database Cardio-Vascular Diseases (CVD).
- Impor Data Massal (Bulk Load): Mempelajari cara memindahkan data dari berkas eksternal (CSV) ke dalam tabel database tanpa perlu menulis perintah INSERT secara manual satu per satu, yang sangat krusial untuk menangani dataset besar.
- Struktur Database Medis: Mengenal hubungan antar tabel dalam skema CVD yang mencakup informasi pasien, riwayat medis, prosedur, departemen, hingga lokasi medis.
- Manajemen via GUI (phpMyAdmin): Memanfaatkan fitur Import pada alat bantu visual untuk mengunggah berkas skrip dan dataset, serta melakukan verifikasi struktur tabel melalui tab Structure.

Module 3

1. hands-on lab: string patterns, sorting and grouping in mysql => menguasai teknik pemfilteran tingkat lanjut dalam MySQL untuk menghasilkan laporan yang lebih presisi, mencakup penggunaan operator LIKE untuk pencarian pola teks, klausa

ORDER BY untuk pengurutan data secara alfabetis atau numerik, serta pemanfaatan GROUP BY dan HAVING untuk melakukan analisis agregat seperti menghitung rata-rata gaji dan jumlah karyawan per departemen.

Poin Utama Lab:

- Pencarian Pola (String Patterns):
 - Menggunakan operator LIKE dan simbol wildcard (%) untuk mencari data yang mengandung kata tertentu (misal: alamat di kota tertentu atau tahun kelahiran di era 70-an).
 - Menggunakan klausa BETWEEN ... AND ... untuk menyaring rentang nilai angka (misal: gaji antara 60.000 hingga 70.000).
 - Pengurutan Data (Sorting):
 - ORDER BY: Secara bawaan mengurutkan dari terkecil ke terbesar (ascending).
 - DESC: Digunakan untuk mengurutkan secara terbalik (dari terbesar ke terkecil). Pengurutan juga bisa dilakukan pada beberapa kolom sekaligus (misal:urut departemen, lalu urut nama belakang).
 - Pengelompokan & Agregasi (Grouping):
 - Menggunakan fungsi COUNT() untuk menghitung anggota kelompok dan AVG() untuk menghitung nilai rata-rata dalam grup.
 - AS (Aliasing): Memberikan label nama baru pada kolom hasil kalkulasi (seperti AVG_SALARY) agar laporan lebih mudah dibaca.
 - Filtrasi Grup (HAVING): Mempelajari perbedaan krusial antara WHERE (filter baris) dan HAVING (filter hasil kelompok), seperti menampilkan hanya departemen yang memiliki jumlah karyawan kurang dari 4 orang.
2. hands-on lab: built-in functions => mengeksplorasi berbagai fungsi bawaan SQL pada MySQL untuk meningkatkan variasi analisis data, mencakup fungsi agregasi untuk kalkulasi numerik, fungsi skalar dan string untuk manipulasi teks, serta fungsi tanggal untuk perhitungan waktu pada dataset penyelamatan hewan (Pet Rescue).

Poin Utama Lab:

- Fungsi Agregasi (Aggregation):
 - SUM, MAX, MIN, AVG: Digunakan untuk operasi matematika pada seluruh kolom, seperti menghitung total biaya penyelamatan atau mencari jumlah hewan terbanyak dalam satu kali penyelamatan.

- Fungsi Skalar & String:
 - ROUND: Membulatkan nilai desimal ke integer terdekat atau jumlah desimal tertentu.
 - LENGTH: Menghitung jumlah karakter dalam sebuah teks.
 - UCASE & LCASE: Mengubah format teks menjadi huruf besar atau huruf kecil untuk standarisasi data.
 - Fungsi Tanggal (Date Functions):
 - DAY, MONTH, YEAR: Mengekstrak bagian spesifik dari data tanggal.
 - DATE_ADD & DATE_SUB: Menambah atau mengurangi interval waktu (hari, bulan, tahun) dari tanggal yang ada.
 - DATEDIFF: Menghitung selisih hari antara dua tanggal (misal: jarak antara tanggal penyelamatan dengan tanggal hari ini).
 - Konstanta Sistem: Menggunakan CURRENT_DATE untuk mendapatkan tanggal hari ini secara otomatis dari server.
3. hands-on lab: working with multiple tables => menguasai teknik pengambilan data dari beberapa tabel secara bersamaan dalam database HR, mencakup penggunaan sub-queries (kueri bersarang) di dalam klausa WHERE untuk memfilter data berdasarkan hasil kueri lain, serta penerapan implicit joins untuk menggabungkan tabel berdasarkan kolom kunci yang beririsan menggunakan alias tabel demi efisiensi penulisan kode.

Poin Utama Lab:

- Sub-Queries (Nested Statements): Mempelajari cara menggunakan hasil dari satu kueri (seperti daftar ID pekerjaan dari tabel JOBS) sebagai filter untuk kueri utama (tabel EMPLOYEES) menggunakan operator IN.
- Implicit Joins: Menggabungkan dua atau lebih tabel dengan menyebutkan semuanya di klausa FROM dan menentukan kriteria penggabungan (relasi antar kunci) di dalam klausa WHERE.
- Aliasing & Fully Qualified Names: * Menggunakan inisial pendek (seperti E untuk EMPLOYEES dan J untuk JOBS) untuk menyederhanakan penulisan.
 - Menentukan asal tabel untuk setiap kolom (misal: E.F_NAME) guna menghindari ambiguitas saat kolom dengan nama yang sama ada di beberapa tabel.

- Integrasi Fungsi Built-in: Mempraktikkan penggabungan tabel yang dikombinasikan dengan fungsi lain, seperti YEAR(B_DATE) untuk memfilter data karyawan berdasarkan tahun lahir saat mengakses informasi pekerjaan.

Module 4

1. hands-on lab: create & access sqlite database using python => mempelajari cara mengelola database relasional ringan menggunakan pustaka sqlite3 langsung di dalam lingkungan Python, yang mencakup alur kerja lengkap mulai dari pembuatan koneksi database, eksekusi perintah DDL dan DML, hingga integrasi data dengan Pandas untuk analisis data yang lebih efisien.

Poin Utama Lab:

- Manajemen Koneksi: Memahami pentingnya membuat koneksi database dan selalu menutupnya menggunakan conn.close() untuk membebaskan sumber daya sistem dan mencegah kebocoran koneksi (unused connections).
 - Operasi Database Dasar: Mempraktikkan pembuatan tabel, memasukkan data (insert), dan melakukan kueri (query) menggunakan sintaks SQL di dalam metode Python.
 - Integrasi Pandas:
 - pd.read_sql_query: Mengonversi hasil kueri SQL secara langsung menjadi objek Pandas DataFrame.
 - Analisis Lanjutan: Memanfaatkan fitur Pandas seperti atribut .shape untuk melihat dimensi dataset atau mengakses baris dan kolom tertentu (misal: df.LNAME[0]) setelah data berhasil ditarik dari database.
 - Otomatisasi Analisis: Menggabungkan kekuatan SQL untuk pengambilan data terstruktur dan Python/Pandas untuk pemrosesan data, yang merupakan fondasi penting bagi seorang analis data atau data scientist.
2. hands-on lab: accessing databases with sql magic => mempelajari cara menyederhanakan interaksi antara Python dan database di lingkungan Jupyter Notebook menggunakan fitur SQL Magic, yang memungkinkan penulisan kueri SQL secara langsung di dalam sel notebook tanpa perlu menulis kode penghubung yang kompleks, serta mengintegrasikan hasilnya dengan pustaka visualisasi data.

Poin Utama Lab:

- Penggunaan SQL Magic (%sql & %%sql): * %sql: Digunakan untuk menjalankan kueri SQL satu baris.

- `%%sql`: Digunakan untuk menjalankan blok kueri SQL multibaris dalam satu sel notebook.
 - Penetapan Variabel Python: Mempelajari cara menyimpan hasil kueri SQL langsung ke dalam variabel Python menggunakan operator `=`, memudahkan pemrosesan data lebih lanjut di luar blok SQL.
 - Konversi ke Pandas DataFrame: Menggunakan metode `.DataFrame()` untuk mengubah objek hasil kueri menjadi Pandas DataFrame, yang memberikan fleksibilitas lebih tinggi untuk manipulasi data.
 - Visualisasi Data: Mengintegrasikan hasil kueri dengan pustaka Seaborn dan Matplotlib untuk membuat grafik (seperti barplot) guna menganalisis distribusi data secara visual, contohnya pada distribusi skor tes siswa internasional.
 - Eksperimen Interaktif: Memberikan ruang bagi pengguna untuk bereksperimen langsung dengan dataset `INTERNATIONAL_STUDENT_TEST_SCORES` untuk melatih kemahiran SQL dalam lingkungan hibrida Python-SQL.
3. analyzing a real world data-set with sql and python => menerapkan kemampuan SQL dan Python untuk melakukan Exploratory Data Analysis (EDA) pada dataset riil (indikator sosioekonomi Chicago), yang mencakup penyimpanan data ke dalam SQLite, penyelesaian masalah bisnis menggunakan kueri kompleks, serta penggunaan visualisasi statistik untuk mengungkap korelasi antar variabel.

Poin Utama Lab:

- Analisis Sosioekonomi Terapan: Menggunakan kueri SQL untuk menjawab pertanyaan spesifik mengenai kondisi masyarakat, seperti mengidentifikasi wilayah dengan indeks kesulitan (hardship index) tertinggi atau area dengan pendapatan per kapita di atas ambang tertentu.
- Teknik Kueri Lanjutan:
 - Menggunakan Sub-query dan fungsi agregasi `MAX()` untuk menemukan nilai ekstrem secara dinamis.
 - Menggunakan klausa `ORDER BY` dan `LIMIT` sebagai alternatif untuk mencari peringkat teratas dalam dataset.
- Visualisasi Korelasi Data:
 - Memanfaatkan pustaka Seaborn (fungsi `jointplot`) untuk membuat scatter plot.

- Mengidentifikasi hubungan korelasi negatif antara dua variabel: menemukan fakta bahwa semakin tinggi pendapatan per kapita, maka indeks kesulitan (hardship index) suatu wilayah cenderung menurun.
 - Insight Berbasis Data: Belajar menceritakan "kisah" di balik angka melalui visualisasi, membantu pengambilan keputusan berdasarkan pola yang terlihat pada grafik daripada sekadar melihat tabel mentah.
4. hands-on lab: connect to db2 database on cloud using python => mempelajari prosedur teknis untuk menghubungkan aplikasi Python ke layanan database IBM Db2 di Cloud menggunakan pustaka `ibm_db`, yang mencakup pengelolaan kredensial koneksi, pengambilan informasi metadata server dan driver, serta praktik terbaik dalam manajemen sumber daya database.

Poin Utama Lab:

- Integrasi Pustaka `ibm_db`: Menggunakan API khusus untuk memfasilitasi komunikasi antara lingkungan Python (seperti Jupyter Notebook) dengan sistem manajemen database relasional (RDBMS) IBM Db2.
 - Keamanan & Kredensial: Memahami pentingnya memasukkan detail koneksi yang akurat (seperti hostname, username, password, dan port) untuk mengautentikasi akses ke database di awan (cloud).
 - Eksplorasi Metadata:
 - * Server Info: Menarik detail mengenai spesifikasi server seperti nama DBMS, versi, dan nama database yang sedang terhubung.
 - Client Info: Memeriksa detail driver lokal, termasuk versi ODBC dan codepage aplikasi untuk memastikan kompatibilitas koneksi.
 - Manajemen Sumber Daya (Resource Management): Menekankan pentingnya menutup koneksi menggunakan `ibm_db.close(conn)` guna mencegah pemborosan sumber daya server akibat koneksi yang tidak terpakai namun tetap terbuka.
5. hands-on lab: access db2 on cloud using python => melanjutkan interaksi dengan IBM Db2 Warehouse on Cloud menggunakan pustaka `ibm_db`, dengan fokus pada manipulasi data langsung dari Python notebook, termasuk pembuatan tabel, pengisian data, serta pemanfaatan Pandas untuk mengolah hasil kueri SQL menjadi format dataframe yang siap dianalisis.

Poin Utama Lab:

- Manipulasi Data (DML & DDL): Mempraktikkan cara mengirim perintah SQL seperti CREATE TABLE dan INSERT melalui API `ibm_db` untuk membangun dan mengisi struktur data di server cloud.
 - Integrasi `pandas.read_sql`: * Mempelajari cara menjembatani data dari Db2 langsung ke dalam ekosistem analisis Python.
 - Menggunakan perintah `pandas.read_sql(selectQuery, pconn)` untuk mengubah hasil kueri menjadi objek Pandas Dataframe secara otomatis.
 - Eksplorasi Data dengan Pandas:
 - Mengakses elemen spesifik dalam dataframe (misal: mengambil nama belakang pada baris pertama dengan `pdf.LNAME[0]`).
 - Melakukan inspeksi dimensi dataset menggunakan atribut `.shape` untuk mengetahui jumlah baris dan kolom yang berhasil ditarik.
 - Kedisiplinan Sumber Daya: Menutup koneksi database dengan `ibm_db.close(conn)` sebagai langkah wajib untuk menjaga performa server dan memastikan tidak ada koneksi "menggantung" yang membuang sumber daya.
6. hands-on lab: accessing databases with sql magic => mempelajari cara menyederhanakan interaksi antara Python dan database IBM Db2 di lingkungan Jupyter Notebook menggunakan fitur SQL Magic, yang memungkinkan penulisan kueri SQL secara langsung tanpa kode penghubung yang rumit, serta mengintegrasikan hasilnya dengan pustaka Pandas dan visualisasi Seaborn.

Poin Utama Lab:

- Efisiensi SQL Magic (`%sql & %%sql`): Memanfaatkan perintah magic untuk menjalankan kueri SQL satu baris maupun blok kueri multibaris langsung di dalam sel notebook, yang jauh lebih praktis daripada menggunakan API standar.
7. analyzing a real world data-set with sql and python => menerapkan teknik analisis data eksploratif (EDA) pada dataset indikator sosioekonomi Chicago tahun 2008–2012 dengan mengintegrasikan Db2 on IBM Cloud dan Python, mulai dari pemuatan data otomatis menggunakan perintah `PERSIST` hingga visualisasi korelasi variabel menggunakan kueri SQL.

Poin Utama Lab:

- Pemahaman Dataset Sosioekonomi: Mengenali variabel kunci seperti Hardship Index (skor 1–100), pendapatan per kapita, tingkat pengangguran, dan tingkat

kemiskinan yang menjadi indikator kesehatan masyarakat di 78 area komunitas Chicago.

- Otomatisasi Penyimpanan Data (PERSIST): Mempelajari cara praktis untuk membaca file CSV dari internet menggunakan Pandas dan langsung menyimpannya sebagai tabel permanen di database Db2 menggunakan perintah Magic SQL %sql PERSIST.
- Analisis Insight dengan SQL:
 - Agregasi & Filter: Menghitung jumlah baris (78) dan mengidentifikasi area dengan tingkat kesulitan tinggi (hardship index > 50.0).
 - Pencarian Nilai Ekstrem: Menggunakan sub-kueri atau klausa ORDER BY untuk menemukan wilayah dengan beban ekonomi terberat (misal: Riverdale dengan indeks 98.0).
- Visualisasi Hubungan Variabel:
 - Mengintegrasikan hasil kueri SQL ke dalam Pandas DataFrame untuk diolah oleh pustaka Seaborn.
- Interpretasi Grafik: Menggunakan jointplot untuk membuktikan adanya korelasi negatif antara pendapatan per kapita dan indeks kesulitan (semakin tinggi pendapatan, semakin rendah tingkat kesulitan wilayah tersebut).
- Instalasi Pustaka Pendukung: Menyiapkan lingkungan analisis dengan menginstal pustaka krusial seperti pandas untuk pengolahan tabel, serta matplotlib dan seaborn untuk kebutuhan presentasi data visual.
- Konversi Hasil ke DataFrame: Menggunakan metode .DataFrame() pada hasil kueri SQL untuk mengubahnya menjadi objek Pandas, sehingga fitur-fitur analisis tingkat lanjut Python dapat diterapkan pada data database.
- Visualisasi Distribusi Data: Mempraktikkan pembuatan grafik batang (barplot) menggunakan Seaborn untuk memvisualisasikan data (misalnya frekuensi skor tes siswa), yang memudahkan identifikasi pola dan tren dibandingkan hanya melihat angka mentah.
- Eksplorasi Interaktif: Mendorong eksperimen mandiri pada dataset INTERNATIONAL_STUDENT_TEST_SCORES untuk melatih kemahiran SQL dalam ekosistem Jupyter yang hibrida.

1. working with a real world data-set using sql and python => mengasah kemahiran analisis data tingkat lanjut menggunakan dataset kinerja Sekolah Publik Chicago, dengan fokus pada penanganan skema database yang kompleks seperti kolom dengan nama sensitif (mixed case) atau karakter khusus, serta menerapkan fungsi bawaan, sub-kueri, dan penggabungan antar tabel untuk mengekstrak wawasan pendidikan dan sosioekonomi.

Poin Utama Lab:

- Manajemen Skema Kompleks: Mempelajari teknik kueri untuk nama kolom yang tidak standar (menggunakan spasi, karakter khusus, atau huruf besar-kecil campuran) yang sering ditemui pada dataset dunia nyata di SQLite.
 - Integrasi Data Multi-Tabel: Mempraktikkan penggabungan data dari dataset pendidikan dengan dataset sosioekonomi (dari lab sebelumnya) untuk melihat gambaran yang lebih luas (misalnya, hubungan antara tingkat kemiskinan wilayah dengan pendaftaran perguruan tinggi).
 - Analisis Berbasis Fungsi: Menggunakan fungsi agregasi, pengurutan (ORDER BY), dan pembatasan hasil (LIMIT) untuk menjawab pertanyaan spesifik, seperti mencari sekolah dengan nilai tes tertinggi atau area dengan beban ekonomi terberat.
 - Eksplorasi Metadata: Mempelajari cara menarik informasi tentang struktur tabel dan tipe data kolom secara programatis menggunakan Python sebelum melakukan kueri data.
2. working with a real world data-set using sql and python => memperdalam keahlian analisis data menggunakan dataset kinerja Sekolah Publik Chicago yang disimpan di Db2 on IBM Cloud, dengan fokus pada teknik kueri tingkat lanjut untuk menangani nama kolom yang kompleks (mixed case atau memiliki spasi), serta mengintegrasikan data pendidikan dengan data sosioekonomi melalui sub-kueri dan fungsi agregasi.

Poin Utama Lab:

- Navigasi Metadata Db2: Mempelajari cara mengambil informasi struktur tabel dan kolom secara programatis dalam lingkungan Db2 untuk memahami tipe data dan batasan kolom sebelum melakukan analisis.
- Penanganan Nama Kolom Sensitif: Menguasai penggunaan tanda kutip ganda (" ") dalam SQL untuk memanggil nama kolom yang memiliki huruf besar-kecil campuran (mixed case) atau karakter khusus agar kueri tidak menghasilkan galat.

- Analisis Data Lintas Tabel: * Mengintegrasikan dataset sekolah dengan dataset indikator sosioekonomi Chicago.
 - Mencari korelasi antara kapasitas sekolah (jumlah pendaftaran) dengan kondisi ekonomi wilayah (hardship index).
 - Optimasi Kueri: Mengasah penggunaan sub-kueri untuk pencarian nilai dinamis, seperti mengidentifikasi wilayah tertentu berdasarkan metrik ekstrem (misal: pendaftaran siswa terbanyak) dari tabel yang berbeda.
3. assignment: notebook for graded assessment => merupakan ujian komprehensif untuk mengintegrasikan seluruh keahlian SQL dan Python yang telah dipelajari. Anda akan mengelola tiga dataset riil (Sensus, Sekolah, dan Kriminalitas Chicago) dalam database SQLite, melakukan manipulasi data menggunakan SQL Magic, dan memecahkan masalah analitis kompleks yang menggabungkan berbagai tabel untuk menarik kesimpulan strategis.

Poin Utama yang Harus Diperhatikan:

- Persiapan Data: Pastikan Anda menggunakan fungsi `df.to_sql()` dari Pandas untuk memasukkan data ke `FinalDB.db` sebelum menjalankan kueri.
- Penanganan Nama Kolom: Dataset sekolah seringkali memiliki nama kolom yang panjang atau mengandung spasi. Gunakan tanda kutip ganda (" ") jika kueri Anda menghasilkan error.
- Logika Sub-query: Masalah 9 dan 10 melatih Anda untuk mengambil data dari satu tabel berdasarkan kriteria yang ditemukan di tabel lain (relasi kunci primer dan asing).
- Analisis Deskripsi: Pada masalah 3 dan 4, penggunaan operator `LIKE` sangat krusial untuk mencari kata kunci spesifik di dalam kolom teks yang panjang.

Module 6

1. hands-on lab: using views in mysql using phpmyadmin => mempelajari konsep View sebagai tabel virtual yang dinamis untuk merepresentasikan data dari satu atau lebih tabel tanpa menyimpan datanya secara fisik. Lab ini mencakup cara menyederhanakan akses data kompleks, menyembunyikan kolom sensitif, dan menggabungkan informasi dari tabel `EMPLOYEES`, `JOBS`, dan `DEPARTMENTS` menggunakan perintah `CREATE VIEW`, `CREATE OR REPLACE VIEW`, dan `DROP VIEW`.

Poin Utama Lab:

- Definisi View: View adalah cara alternatif untuk menampilkan data. View bersifat dinamis; hanya definisinya yang disimpan di database, sementara datanya tetap mengambil dari tabel asli (base tables).
 - Keamanan & Penyederhanaan: Digunakan untuk menampilkan kolom tertentu saja (misal: hanya nama dan gaji) guna melindungi data sensitif lainnya atau untuk mempermudah kueri yang sering digunakan.
 - Pembaruan Skema (Update View): Menggunakan klausa CREATE OR REPLACE VIEW untuk mengubah definisi view yang sudah ada tanpa harus menghapusnya terlebih dahulu. Ini memungkinkan penambahan kolom dari tabel lain melalui teknik Implicit Join.
 - Manajemen View: Memahami bahwa view dapat dipanggil dengan perintah SELECT layaknya tabel biasa, namun dapat dihapus secara permanen menggunakan perintah DROP VIEW tanpa memengaruhi data pada tabel aslinya.
2. hands-on lab: Acid Transactions in MySQL using Stored Procedures => mempelajari cara mengelola transaksi database yang melibatkan beberapa tabel secara atomik menggunakan TCL (Transaction Control Language). Lab ini fokus pada penggunaan perintah COMMIT untuk menyimpan perubahan secara permanen dan ROLLBACK untuk membatalkan seluruh rangkaian perintah jika terjadi kegagalan, guna menjaga integritas data pada tabel BankAccounts dan ShoeShop.

Poin Utama Lab:

- Konsep Atomisitas (Atomicity): Memahami bahwa dalam sebuah transaksi, semua perintah harus berhasil dijalankan. Jika satu perintah gagal (misal: saldo tidak mencukupi), maka seluruh perintah sebelumnya dalam blok transaksi tersebut harus dibatalkan.
- Stored Procedure untuk Transaksi: Menggunakan CREATE PROCEDURE untuk membungkus logika bisnis yang kompleks. Di dalamnya terdapat penanganan kesalahan (DECLARE EXIT HANDLER FOR SQLEXCEPTION) yang secara otomatis memicu ROLLBACK jika terjadi galat SQL.
- Alur Kerja TCL:
 - START TRANSACTION: Menandai titik awal blok transaksi.
 - COMMIT: Mengonfirmasi bahwa semua operasi berhasil dan menyimpan perubahan ke database secara permanen.

- ROLLBACK: Mengembalikan database ke kondisi semula sebelum transaksi dimulai jika ada salah satu pernyataan yang gagal.
 - Penerapan Dunia Nyata: Mensimulasikan proses belanja (pengurangan saldo pembeli, penambahan saldo toko, dan pengurangan stok barang) yang memerlukan konsistensi data di dua tabel berbeda.
3. hands-on lab: Joins in MySQL => mempelajari teknik menggabungkan data dari beberapa tabel berbeda dalam database HR menggunakan berbagai tipe JOIN. Lab ini berfokus pada cara menghubungkan tabel EMPLOYEES, JOB_HISTORY, JOBS, dan DEPARTMENTS untuk menghasilkan laporan yang komprehensif berdasarkan relasi kunci antar tabel.

Poin Utama Lab:

- INNER JOIN: Digunakan untuk mengambil baris dari kedua tabel yang memenuhi kondisi kecocokan. Contohnya, menggabungkan data karyawan dengan sejarah pekerjaan mereka hanya untuk record yang memiliki ID karyawan yang sama di kedua tabel.
- LEFT OUTER JOIN: Mengambil semua baris dari tabel kiri (misal: EMPLOYEES) dan baris yang cocok dari tabel kanan (misal: DEPARTMENTS). Jika tidak ada kecocokan di tabel kanan, maka kolom tersebut akan berisi nilai NULL.
- FULL OUTER JOIN (MySQL Workaround): MySQL tidak memiliki perintah FULL OUTER JOIN secara langsung. Solusinya adalah dengan melakukan UNION antara hasil LEFT OUTER JOIN dan RIGHT OUTER JOIN untuk mendapatkan semua record dari kedua tabel.
- Multi-Table Join: Teknik menggabungkan lebih dari dua tabel dalam satu kueri (misal: menggabungkan EMPLOYEES, JOB_HISTORY, dan JOBS) untuk menarik informasi yang tersebar di berbagai bagian skema database.
- Kondisi Gabungan Lanjutan: Menambahkan filter tambahan menggunakan operator AND langsung di dalam klausa ON untuk menyaring data selama proses penggabungan (misal: memfilter berdasarkan tahun lahir atau jenis kelamin).

COURSE 7

Module 1

1. hands-on lab: importing dataset => mempelajari langkah-langkah dasar dalam akuisisi data dan eksplorasi awal menggunakan pustaka Pandas. Lab ini berfokus pada cara memuat dataset ke dalam Python, memverifikasi struktur data, serta mendapatkan wawasan cepat mengenai tipe data dan kualitas data (seperti mengidentifikasi nilai yang hilang) sebelum melanjutkan ke tahap analisis.

Poin Utama Lab:

- Pemuatan Data (Data Acquisition): Mempelajari cara mengimpor data dari berbagai sumber ke dalam format DataFrame Pandas, yang merupakan struktur data dua dimensi yang efisien untuk manipulasi tabel.
- Inspeksi Struktur Data (df.info()): * Mendapatkan ringkasan ringkas mengenai DataFrame, termasuk jumlah total entri (indeks).
 - Memeriksa jumlah kolom dan nama masing-masing kolom.
 - Mengidentifikasi jumlah nilai yang non-null (bukan nol/kosong) untuk mendeteksi data yang hilang sejak dini.
- Pemahaman Tipe Data (Dtypes): Mengenali perbedaan antara tipe data numerik (int64, float64) dan tipe data string atau campuran (object). Hal ini krusial untuk menentukan operasi matematika yang bisa dilakukan pada kolom tertentu.
- Manajemen Memori: Memantau penggunaan memori dataset guna memastikan efisiensi pemrosesan, terutama pada dataset yang berukuran besar.

Module 2

1. hands-on practice lab: importing dataset - laptops pricing => mempraktikkan proses pemuatan dataset baru mengenai harga laptop ke dalam Python menggunakan Pandas. Lab ini berfokus pada teknik dasar pemeriksaan struktur data untuk memahami komposisi variabel, mengidentifikasi tipe data, dan mendeteksi keberadaan data yang hilang (missing values) sebagai langkah awal sebelum tahap pembersihan data.

Poin Utama Lab:

- Eksplorasi Skema Dataset: Dataset "Laptop Pricing" terdiri dari 238 entri dengan 12 kolom yang mencakup spesifikasi teknis (seperti RAM, CPU, GPU) dan informasi pasar (Produsen dan Harga).
- Inspeksi Ringkasan Data (df.info()):
 - Identifikasi Tipe Data: Menemukan variasi tipe data seperti int64 untuk kuantitas (RAM, Storage), float64 untuk frekuensi CPU, dan object untuk kategori tekstual (Manufacturer, Screen).

- Deteksi Nilai Hilang: Melalui output ringkasan, terlihat bahwa kolom `Screen_Size_inch` (234 nilai non-null) dan `Weight_kg` (233 nilai non-null) memiliki data yang tidak lengkap dibandingkan total 238 baris.
 - Analisis Penggunaan Memori: Dataset ini relatif ringan dengan penggunaan memori sekitar 18.7+ KB, yang memungkinkan pemrosesan cepat dalam lingkungan pengembangan.
 - Validasi Data Teknis: Menemukan bahwa beberapa kolom teknis seperti `Weight_kg` masih bertipe object, yang mengindikasikan perlunya konversi tipe data ke numerik agar dapat digunakan dalam perhitungan matematis atau pemodelan harga nantinya.
2. hands-on practice lab: data wrangling - laptops pricing => menerapkan teknik pembersihan dan transformasi data pada dataset harga laptop untuk memastikan konsistensi dan kesiapan analisis. Lab ini berfokus pada penanganan nilai yang hilang pada spesifikasi fisik, koreksi tipe data, serta penerapan standardisasi satuan (berat) dan normalisasi fitur untuk menghilangkan bias skala antar variabel.

Poin Utama Lab:

- Pembersihan Data Spesifik: Mengatasi masalah data yang tidak lengkap pada atribut seperti ukuran layar dan berat laptop, baik dengan cara pengisian nilai (imputation) maupun penghapusan baris yang tidak valid.
- Standardisasi Atribut: Mengonversi satuan berat dari kilogram ke pound (`Weight_pounds`) untuk memenuhi standar pelaporan tertentu, memastikan data memiliki satuan yang seragam di seluruh dataset.
- Normalisasi & Penskalaan: Menyesuaikan rentang nilai pada fitur teknis (seperti frekuensi CPU) agar model analisis tidak terpengaruh oleh perbedaan besaran angka yang mencolok antar kolom.
- Binning (Pengelompokan): Mengonversi variabel numerik berkelanjutan (seperti Price) menjadi kategori diskrit (Price-binned: Low, Medium, High) untuk memudahkan analisis segmentasi pasar.
- Indikator Variabel (One-Hot Encoding): Mengubah fitur kategorikal seperti jenis layar (Screen) menjadi kolom boolean (`Screen-Full_HD`, `Screen-IPS_panel`) agar dapat diolah oleh algoritma statistik.

1. hands-on lab: exploratory data analysis => mempelajari teknik investigasi awal pada dataset otomotif untuk menemukan pola, mendeteksi anomali, dan menguji hipotesis melalui statistik deskriptif dan visualisasi. Lab ini berfokus pada identifikasi fitur-fitur kunci yang memiliki pengaruh signifikan terhadap variabel target (harga mobil) untuk mempersiapkan data sebelum tahap pemodelan mesin (machine learning).

Poin Utama Lab:

- Statistik Deskriptif: Menggunakan metode `.describe()` untuk mendapatkan ringkasan statistik (rata-rata, standar deviasi, kuartil) guna memahami sebaran data numerik dan kategori.
- Analisis Pengelompokan (Grouping): Mempraktikkan metode `.groupby()` untuk menganalisis variabel kategori (seperti jenis roda penggerak/drive-wheels) dan melihat dampaknya terhadap rata-rata harga melalui pembuatan Pivot Tables.
- Korelasi dan Hubungan Variabel:
 - Variabel Numerik Kontinu: Mengidentifikasi hubungan linier antara spesifikasi teknis (ukuran mesin, tenaga kuda) dengan harga menggunakan korelasi Pearson.
 - Variabel Kategorikal: Menggunakan visualisasi seperti box plots untuk melihat variasi harga pada kategori yang berbeda.
- Pemilihan Fitur (Feature Selection): Menyaring variabel yang "bermakna" (memiliki korelasi kuat) untuk meningkatkan performa prediksi model, seperti engine-size, horsepower, dan curb-weight.

2. hands-on lab: exploratory data analysis - laptops pricing dataset => melakukan investigasi mendalam terhadap faktor-faktor teknis yang memengaruhi harga laptop menggunakan analisis statistik tingkat lanjut. Lab ini berfokus pada penggunaan korelasi Pearson dan nilai P-value untuk memvalidasi secara ilmiah fitur mana yang memiliki hubungan paling kuat dan signifikan secara statistik terhadap harga jual laptop.

Poin Utama Lab:

- Analisis Korelasi Pearson: Mengukur kekuatan hubungan linier antara variabel independen (spesifikasi) dan variabel target (harga). Koefisien mendekati 1 menunjukkan hubungan positif yang kuat.

- Signifikansi Statistik (P-value): Menggunakan nilai P-value untuk menentukan tingkat kepercayaan hasil korelasi. Nilai $P < 0,001$ dianggap sebagai bukti yang sangat kuat bahwa korelasi tersebut signifikan secara statistik.
- Identifikasi Prediktor Utama: Berdasarkan hasil pengujian, fitur seperti RAM_GB ($\$0,54$) dan CPU_core ($\$0,45$) menunjukkan korelasi positif yang paling kuat dibandingkan fitur lainnya.
- Evaluasi Fitur Lemah: Menemukan bahwa fitur seperti Weight_pounds dan Screen_Size_inch memiliki korelasi yang sangat rendah dan nilai P-value yang tinggi ($P > 0,05$), menandakan bahwa variabel ini bukan prediktor yang andal untuk menentukan harga laptop dalam dataset ini.

Module 4

1. hands-on lab: model development => mempelajari cara membangun model matematika untuk memprediksi harga mobil berdasarkan fitur-fitur yang telah diidentifikasi pada tahap EDA. Lab ini berfokus pada implementasi berbagai teknik regresi, mulai dari model linear sederhana hingga model polinomial yang lebih kompleks, serta cara mengevaluasi model mana yang paling akurat menggunakan metrik statistik.

Poin Utama Lab:

- Linear Regression (SLR): Membuat model prediksi menggunakan satu variabel independen (misal: highway-mpg) untuk memahami hubungan dasar terhadap harga.
- Multiple Linear Regression (MLR): Mengembangkan model yang lebih canggih dengan menggabungkan beberapa variabel prediktor sekaligus (seperti horsepower, curb-weight, engine-size, dan highway-mpg) untuk meningkatkan akurasi prediksi.
- Polynomial Regression: Menerapkan transformasi polinomial pada data ketika hubungan antara fitur dan harga tidak bersifat linier (melengkung), guna menangkap pola data yang lebih kompleks.
- Pipeline: Mempelajari cara menyederhanakan proses pengembangan model dengan menyatukan tahap normalisasi, transformasi polinomial, dan regresi ke dalam satu alur kerja yang rapi.
- Evaluasi Model (R-squared & MSE):

- R^2 (Coefficient of Determination): Mengukur seberapa dekat data dengan garis regresi yang dibuat (semakin dekat ke 1, semakin baik).
 - MSE (Mean Squared Error): Mengukur rata-rata selisih kuadrat antara nilai prediksi dan nilai aktual (semakin kecil, semakin baik).
2. hands-on practice lab: model development - laptops pricing => menerapkan prinsip regresi linear untuk membangun model prediktif harga laptop. Lab ini berfokus pada evolusi kompleksitas model, mulai dari regresi linear tunggal hingga penggunaan Pipeline yang menggabungkan penskalaan data, pembuatan fitur polinomial, dan regresi linear berganda untuk mencapai akurasi prediksi yang lebih tinggi.

Poin Utama Lab:

- Evolusi Akurasi Model: Lab ini menunjukkan bahwa nilai R^2 (koefisien determinasi) meningkat secara bertahap seiring bertambahnya kompleksitas model:
 - Single Linear Regression (SLR): Dasar prediksi dengan satu variabel.
 - Multiple Linear Regression (MLR): Menggunakan banyak variabel untuk hasil yang lebih baik.
 - Polynomial Multiple Regression: Hasil terbaik dicapai ketika fitur MLR diperluas dengan transformasi polinomial.
- Otomatisasi dengan Pipeline: Menggunakan `sklearn.pipeline.Pipeline` untuk menyatukan tiga tahap krusial menjadi satu alur kerja yang efisien:
 - `StandardScaler()`: Menyamakan skala semua fitur teknis laptop.
 - `PolynomialFeatures()`: Menangkap hubungan non-linier antar fitur.
 - `LinearRegression()`: Melakukan komputasi prediksi harga akhir.
- Evaluasi Metrik: Menggunakan MSE (Mean Squared Error) untuk melihat rata-rata kesalahan kuadrat dan R^2 untuk mengukur seberapa besar variasi harga yang dapat dijelaskan oleh model.

Module 5

1. hands-on lab: model evaluation and refinement => mempelajari teknik lanjutan untuk memvalidasi dan mengoptimalkan model prediksi harga menggunakan dataset otomotif. Lab ini berfokus pada penggunaan Ridge Regression untuk menangani overfitting, penerapan Grid Search untuk menemukan parameter terbaik secara

otomatis, serta pentingnya Feature Scaling guna memastikan semua variabel prediktor memberikan kontribusi yang seimbang terhadap akurasi model.

Poin Utama Lab:

- Pentingnya Feature Scaling: Menggunakan StandardScaler untuk menyamakan skala fitur (seperti horsepower dan engine-size) sehingga fitur dengan rentang angka besar tidak mendominasi model secara tidak adil dibandingkan fitur dengan rentang angka kecil.
- Optimalisasi Hyperparameter: Menerapkan GridSearchCV untuk menguji berbagai nilai Alpha (α) pada regresi Ridge secara sistematis. Alpha berfungsi sebagai penalti untuk mencegah bobot model menjadi terlalu kompleks (overfitting).
- Validasi Silang (Cross-Validation): Menggunakan parameter $cv=4$ dalam Grid Search untuk memastikan bahwa model diuji pada bagian data yang berbeda-beda, sehingga hasil evaluasi lebih objektif dan stabil.
- Penyempurnaan Model Ridge: Mengidentifikasi bahwa nilai Alpha yang tepat dapat menyeimbangkan antara performa pada data latih (training) dan kemampuan generalisasi pada data baru (testing).

2. hands-on practice lab: model evaluation and refinement - laptops pricing => menerapkan teknik validasi silang dan optimalisasi hyperparameter untuk meningkatkan performa prediksi harga laptop. Lab ini berfokus pada penggunaan Ridge Regression dan Grid Search untuk menemukan nilai alpha yang paling efisien, guna memastikan model memiliki kemampuan generalisasi yang baik saat diuji dengan data yang belum pernah dilihat sebelumnya.

Poin Utama Lab:

- Pembagian Data Latih & Uji: mempraktikkan pemisahan dataset menjadi x_{train} dan x_{test} untuk mengevaluasi performa model secara objektif dan menghindari bias memori pada data yang sudah dipelajari.
- Optimalisasi Ridge Regression: Menggunakan regresi Ridge untuk memitigasi risiko overfitting yang sering terjadi pada model dengan banyak fitur teknis (seperti RAM, CPU, dan GPU).
- Grid Search untuk Pencarian Alpha: Menggunakan GridSearchCV untuk mengotomatiskan pengujian berbagai nilai parameter penalti (α). Proses ini membantu menemukan titik keseimbangan antara kesalahan pada data latih dan data uji.

- Ekstraksi Estimator Terbaik: Mempelajari cara mengambil model yang sudah dioptimalkan (`best_estimator_`) untuk melakukan prediksi final dengan tingkat akurasi tertinggi yang dimungkinkan oleh dataset tersebut.

Module 6

1. practice project: insurance cost analysis => merupakan proyek integratif yang menerapkan seluruh siklus data science untuk memprediksi biaya asuransi tahunan. Proyek ini mencakup pembersihan data (menangani entri kosong), analisis statistik untuk mengidentifikasi faktor risiko utama (seperti age, bmi, dan smoker), serta pengembangan dan penyempurnaan model regresi menggunakan transformasi polinomial dan regularisasi Ridge untuk mencapai akurasi prediksi yang optimal.

Poin Utama Proyek:

- Pembersihan & Pra-pemrosesan Data: Mengonversi data kategorikal (seperti gender dan region) menjadi format numerik dan menangani nilai yang hilang guna memastikan dataset siap untuk pemodelan matematis.
 - Analisis Faktor Kunci (EDA): Mengidentifikasi hubungan antara karakteristik individu dengan biaya asuransi. Parameter seperti status merokok (smoker) dan indeks massa tubuh (bmi) ditemukan memiliki pengaruh signifikan terhadap beban biaya.
 - Transformasi Polinomial: Menerapkan transformasi derajat 2 ($\text{degree}=2$) pada fitur pelatihan. Teknik ini memungkinkan model untuk menangkap hubungan non-linier antara variabel independen dan biaya asuransi, yang sering kali lebih akurat daripada regresi linear sederhana.
 - Regularisasi Ridge: Menggunakan regresi Ridge pada fitur polinomial untuk mencegah overfitting. Dengan menambahkan penalti, model tetap stabil meskipun bekerja dengan dimensi data yang lebih tinggi setelah transformasi.
2. final project: house sales in king county, usa => merupakan tugas integratif komprehensif untuk memprediksi harga rumah di King County (termasuk Seattle) menggunakan dataset nyata yang kaya akan fitur. Proyek ini menantang kamu untuk menerapkan seluruh spektrum keahlian data science—mulai dari pembersihan data, analisis statistik deskriptif, hingga pengembangan model regresi tingkat lanjut untuk menghasilkan prediksi harga properti yang akurat.

Tujuan & Alur Kerja Utama Proyek:

- Eksplorasi Data (EDA): Menganalisis bagaimana fitur seperti luas tanah (sqft_living), jumlah kamar mandi, pemandangan air (waterfront), dan kondisi bangunan memengaruhi nilai pasar rumah.
- Data Wrangling: Menangani nilai yang hilang, menghapus kolom yang tidak relevan (seperti ID atau kode pos), dan memastikan tipe data siap untuk pemrosesan algoritma.
- Model Development: * Membangun model Linear Regression tunggal dan berganda.
 - Menerapkan Polynomial Features untuk menangkap hubungan kompleks antar variabel.
- Model Refinement: Menggunakan regresi Ridge untuk menjaga stabilitas model dan mencegah overfitting, terutama saat menggunakan fitur polinomial derajat tinggi.
- Pipelines: Mengotomatiskan seluruh alur kerja (skala data, transformasi, dan regresi) ke dalam satu fungsi terintegrasi untuk efisiensi kueri.

3. final assignment: data analytics for house pricing data set =>

- Penyelesaian Proyek & Submission (Q1): Melengkapi dan mengunggah Jupyter Notebook yang mendemonstrasikan alur kerja komprehensif, mulai dari pembersihan data (menghapus kolom ID), eksplorasi fitur teknis (luas tanah, lantai, pemandangan air), hingga pembangunan model regresi linear dan Ridge untuk prediksi harga rumah di King County.
- Transformasi & Pembersihan Data (Q2 - Q5): Memahami penggunaan fungsi dtypes untuk identifikasi format data, menerapkan strategi penanganan nilai yang hilang (missing values), serta menggunakan teknik value_counts yang dikonversi ke DataFrame untuk menganalisis distribusi kategori seperti jumlah lantai rumah.
- Analisis Korelasi & Visualisasi (Q6 & Q12): Menginterpretasikan hasil visualisasi regplot untuk menentukan kekuatan hubungan antara luas area (sqft_above) dengan harga, serta menggunakan boxplot untuk mengidentifikasi fitur yang memiliki varians atau pencilan (outliers) paling signifikan, khususnya pada kategori rumah dengan pemandangan air.
- Evaluasi Model Prediktif (Q7, Q8 & Q13): Memahami makna metrik statistik seperti R^2 (misalnya arti skor 0.49), menentukan rentang akurasi yang wajar pada data uji, serta mengidentifikasi faktor kunci dalam penerapan regresi polinomial derajat dua untuk menangkap pola data yang kompleks.

- Otomatisasi & Optimalisasi Model (Q9 - Q11): Memanfaatkan keunggulan Pipeline untuk menyatukan tahap penskalaan dan pemodelan dalam satu alur kerja, mengimplementasikan fungsi regresi linear dari pustaka scikit-learn, serta memahami peran parameter Alpha pada regresi Ridge dalam mengontrol kompleksitas model (regularisasi).

COURSE 8

Module 1

1. exploring and pre-processing a dataset using pandas => mempelajari teknik dasar hingga menengah dalam menggunakan pustaka Pandas untuk mengolah data sebelum tahap visualisasi. Lab ini menggunakan dataset imigrasi Kanada (1980–2013) untuk melatih kemampuan manipulasi struktur data, pembersihan kolom yang tidak diperlukan, serta teknik penyaringan data berdasarkan kriteria tertentu.

Poin Utama Lab:

- Eksplorasi Dasar Data: Menggunakan fungsi head(), tail(), info(), dan describe() untuk mendapatkan gambaran cepat mengenai struktur, tipe data, dan statistik deskriptif dari dataset yang dimuat.
- Pembersihan Data (Data Wrangling):
 - Menghapus Kolom: Menggunakan drop() untuk mengeliminasi kolom yang tidak relevan bagi analisis (seperti AREA, REG, DEV).
 - Mengubah Nama Kolom: Menggunakan rename() dengan kamus (dictionary) untuk mempermudah pembacaan data (misal: OdName menjadi Country).
 - Menangani Nilai Kosong: Melakukan pengecekan data yang hilang menggunakan isnull().sum().
- Manipulasi Indeks & Seleksi:
 - Set Index: Mengubah kolom Country menjadi indeks dataset menggunakan set_index() untuk mempermudah pencarian data berdasarkan nama negara.
 - Seleksi Baris & Kolom: Membedakan penggunaan .loc[] (berdasarkan label/nama) dan .iloc[] (berdasarkan posisi angka/indeks) untuk mengambil data spesifik.

- Transformasi Tipe Data: Mengonversi nama kolom tahun yang bertipe integer menjadi string menggunakan `map(str, df_can.columns)` guna menghindari ambiguitas saat melakukan seleksi data di tahap lanjut.
 - Operasi Agregasi: Menambahkan kolom baru (Total) yang menjumlahkan seluruh angka imigrasi per negara selama rentang tahun 1980–2013 menggunakan fungsi `sum(axis=1)`.
2. introduction to matplotlib and line plots => mempelajari cara memvisualisasikan tren data deret waktu (time-series) menggunakan pustaka Matplotlib. Lab ini berfokus pada teknik pembuatan grafik garis (line plot) untuk membandingkan fluktuasi data imigrasi antar negara selama periode 34 tahun, serta memahami bagaimana elemen estetika grafik dapat meningkatkan keterbacaan data.

Poin Utama Lab:

- Persiapan Data untuk Visualisasi: Memahami bahwa struktur data untuk grafik garis memerlukan tahun sebagai indeks. Teknik transposisi (`.transpose()`) digunakan untuk menukar baris (negara) menjadi kolom, sehingga sumbu x (tahun) dapat diplot secara kronologis.
- Pengurutan Data Strategis: Menggunakan `sort_values()` berdasarkan kolom Total untuk mengidentifikasi 5 negara penyumbang imigran terbesar secara kumulatif (India, China, UK, Filipina, dan Pakistan).
- Kustomisasi Grafik Matplotlib:
 - Ukuran Gambar: Menggunakan parameter `figsize=(14, 8)` untuk memperbesar tampilan grafik agar tren yang tumpang tindih lebih mudah dianalisis.
 - Pelabelan: Menambahkan konteks melalui `plt.title()`, `plt.ylabel()`, dan `plt.xlabel()` guna memastikan informasi yang disampaikan jelas bagi audiens.
- Fleksibilitas Plotting: Mengenal parameter `kind` pada fungsi `.plot()`, yang memungkinkan pengguna beralih dengan mudah ke jenis grafik lain seperti bar (batang), hist (histogram), pie (lingkaran), hingga scatter (sebar).

Module 2

1. area plots, histograms, and bar charts => mempelajari teknik visualisasi data tingkat menengah untuk menggambarkan distribusi, perbandingan kategori, dan akumulasi data imigrasi Kanada (1980–2013). Lab ini menekankan pada penyesuaian estetika grafik

menggunakan gaya ggplot serta perbedaan antara metode plotting Scripting Layer dan Artist Layer.

Poin Utama Lab:

- Area Plots (Stacked Line Plots):
 - Visualisasi Kumulatif: Menggambarkan kontribusi relatif antar kelompok (negara) terhadap total keseluruhan dari waktu ke waktu.
 - Parameter Transparansi: Mengatur tingkat tembus pandang menggunakan alpha (0–1) untuk menangani tumpang tindih pada unstacked plot.
 - Metode Plotting: Memahami Artist Layer (Object-Oriented) yang menggunakan instans Axes (seperti `ax.set_title()`) untuk fleksibilitas lebih tinggi pada grafik kompleks.
 - Histograms:
 - Distribusi Frekuensi: Mengelompokkan data numerik ke dalam bins (interval) untuk melihat konsentrasi jumlah imigran.
 - Sinkronisasi Sumbu X: Menggunakan `np.histogram` untuk mendapatkan `bin_edges` agar label pada sumbu x sesuai dengan batas interval yang sebenarnya.
 - Penyelarasan Struktur: Melakukan transposisi data saat memplot beberapa negara sekaligus agar tahun menjadi sumbu horizontal.
 - Bar Charts (Vertical & Horizontal):
 - Analisis Kejadian: Menggunakan bar vertikal (`kind='bar'`) untuk menyoroti perubahan drastis, seperti dampak krisis keuangan Islandia tahun 2008.
 - Keterbacaan Label: Menggunakan bar horizontal (`kind='barh'`) saat bekerja dengan banyak kategori (Top 15 Negara) agar label nama negara lebih mudah dibaca.
 - Annotasi Lanjut: Menambahkan elemen teks dan panah menggunakan `plt.annotate()` untuk memberikan konteks naratif pada titik data spesifik di dalam grafik.
2. pie charts, box plots, scatter plots, and bubble plots => mengeksplorasi teknik visualisasi data tingkat lanjut untuk mengungkap proporsi, statistik distribusi, tren korelasi, dan pengaruh variabel ketiga (bobot) dalam data imigrasi Kanada. Lab ini menitikberatkan pada penggunaan fungsi `groupby` untuk agregasi data dan teknik normalisasi untuk pembuatan grafik gelembung (bubble plot).

Poin Utama Lab:

- Pie Charts (Grafik Lingkaran):
 - Analisis Proporsi: Digunakan untuk membandingkan kontribusi imigrasi antar benua secara persentase terhadap total keseluruhan.
 - Estetika & Penekanan: Menggunakan parameter `explode` untuk memisahkan irisan tertentu dan `autopct` untuk menampilkan label persentase secara otomatis di dalam atau di luar lingkaran.
 - Box Plots (Diagram Kotak):
 - Ringkasan Statistik: Menampilkan lima dimensi utama (Min, Q1, Median, Q3, Max) serta mendeteksi pencilan (outliers) secara visual.
 - Analisis Komparatif: Sangat efektif untuk membandingkan variabilitas imigrasi antar negara (misal: India vs. China) atau tren antar dekade (80-an, 90-an, 2000-an).
 - Scatter Plots (Grafik Sebar):
 - Analisis Tren: Memetakan hubungan antara dua variabel numerik (tahun vs. total imigran) untuk melihat pola kenaikan atau penurunan.
 - Regresi Linear: Menggunakan `np.polyfit()` untuk menarik garis tren terbaik (line of best fit) yang dapat digunakan untuk memprediksi angka imigrasi di masa depan.
 - Bubble Plots (Grafik Gelembung):
 - Tiga Dimensi Data: Menampilkan sumbu x, sumbu y, dan dimensi ketiga berupa ukuran gelembung yang mewakili bobot (weight).
 - Normalisasi Data: Menerapkan feature scaling (mengubah rentang data menjadi 0–1) agar ukuran gelembung proporsional dan dapat dibandingkan antar negara (misal: Brazil vs. Argentina selama masa krisis ekonomi).
3. plotting directly with matplotlib => berfokus pada kemahiran menggunakan Artist Layer untuk kontrol penuh atas tata letak grafik. Inti dari lab ini adalah penguasaan fungsi subplots, yang memungkinkan penggabungan berbagai jenis visualisasi (garis, sebar, histogram, dan lingkaran) ke dalam satu bingkai (figure) yang terorganisir, sehingga mempermudah analisis komparatif dalam satu tampilan terpadu.

Poin Utama Lab:

- Struktur Kisi (Grid Layout):

- Menggunakan `plt.figure()` dan `add_subplot(nrows, ncols, index)` untuk menciptakan tata letak 2x2.
- Memahami koordinat plot di mana (2, 2, 1) adalah posisi kiri-atas dan (2, 2, 4) adalah kanan-bawah.
- Integrasi Multi-Visualisasi:
 - Menggabungkan empat teknik utama: Line Plot (tren), Scatter Plot (korelasi), Histogram (distribusi), dan Pie Chart (proporsi).
 - Menyesuaikan setiap sumbu (ax) secara independen dengan judul, label, dan warna yang spesifik.
- Manajemen Ruang dan Estetika:
 - `fig.suptitle()`: Menambahkan judul utama untuk keseluruhan koleksi grafik agar audiens memahami tema besar data.
 - `fig.tight_layout()`: Mengatur jarak antar plot secara otomatis agar label sumbu dan judul tidak saling tumpang tindih.

Module 3

1. waffle charts, word clouds, and regression plots => memperkenalkan cara memvisualisasikan data non-tradisional dan analisis statistik tingkat lanjut. Lab ini berfokus pada penggunaan Waffle Charts untuk melihat komposisi, Word Clouds untuk data tekstual, dan pustaka Seaborn untuk membuat plot regresi yang lebih canggih dan estetis guna mengidentifikasi tren data secara otomatis.

Poin Utama Lab:

- Waffle Charts:
 - Visualisasi Komposisi: Alternatif yang lebih jelas dari Pie Chart untuk menampilkan proporsi kategori dalam satu kesatuan.
 - Struktur: Menggunakan kisi-kisi (grid) di mana setiap kotak mewakili persentase tertentu dari total, memudahkan audiens membandingkan kontribusi relatif antar negara.
- Word Clouds:
 - Data Tekstual: Memvisualisasikan frekuensi kata dalam dokumen atau dataset. Semakin besar ukuran kata, semakin tinggi frekuensi kemunculannya.

- Aplikasi: Sangat berguna untuk ringkasan cepat dari data kualitatif atau melihat negara mana yang paling dominan dalam narasi imigrasi.
- Regression Plots (Seaborn):
 - Analisis Otomatis: Menggunakan `sns.regplot()` untuk membuat scatter plot sekaligus menghitung dan menggambar garis regresi linear beserta interval kepercayaan (confidence interval) secara otomatis.
 - Kustomisasi Seaborn: Memanfaatkan `sns.set_style()` dan `font_scale` untuk meningkatkan kualitas visual grafik agar lebih siap dipresentasikan.
- 2. creating maps and visualizing geospatial data with folium => memperkenalkan penggunaan pustaka Folium untuk membangun visualisasi berbasis peta yang interaktif. Berbeda dengan Matplotlib yang bersifat statis, Folium memungkinkan pembuatan peta dunia, penandaan lokasi insiden kriminal secara detail (markers), serta pembuatan peta tematik (Choropleth) yang mengintegrasikan data statistik dengan batas-batas geografis menggunakan file GeoJSON.

Poin Utama Lab:

- Pengenalan Folium:
 - Peta Interaktif: Folium dibangun di atas pustaka Leaflet.js, memungkinkan pengguna untuk melakukan zoom dan navigasi pada peta yang dihasilkan di dalam dashboard.
 - Gaya Peta (Tiles): Tersedia berbagai gaya visual seperti OpenStreetMap (default), Cartodb dark_matter (tema gelap untuk kontras tinggi), dan Cartodb positron (tema terang yang bersih dan modern).
- Map with Markers (Penanda Lokasi):
 - Circle Markers: Digunakan untuk menandai titik spesifik (seperti lokasi kriminal di San Francisco) dengan kustomisasi warna dan radius.
 - Pop-up Labels: Menambahkan interaktivitas di mana detail informasi (seperti kategori kejahatan) muncul saat penanda diklik atau diarahkan oleh kursor.
 - Marker Clustering: Menggunakan plugin MarkerCluster untuk mengelompokkan titik-titik data yang padat menjadi angka agregat, yang akan terurai secara otomatis saat peta diperbesar (zoom in).
- Choropleth Maps (Peta Koroplet):

- Integrasi Data & GeoJSON: Menghubungkan data tabular (seperti total imigrasi per negara) dengan koordinat batas wilayah dari file GeoJSON.
- Skala Warna: Menggunakan intensitas warna (misal: kuning ke merah) untuk menunjukkan besaran variabel statistik; semakin gelap warnanya, semakin tinggi nilai datanya di wilayah tersebut.

Module 4

1. basic plotly charts => memperkenalkan penggunaan pustaka Plotly untuk membuat grafik yang jauh lebih dinamis dan interaktif dibandingkan pustaka tradisional. Lab ini menekankan pada dua modul utama: `plotly.graph_objects` untuk kontrol kustomisasi tingkat tinggi dan `plotly.express` untuk pembuatan grafik yang cepat dan efisien, sangat cocok untuk kebutuhan data science dan pembuatan dashboard.

Poin Utama Lab:

- Pustaka Plotly:
 - Plotly Express (px): Pendekatan tingkat tinggi yang memungkinkan pembuatan grafik kompleks (seperti scatter, line, dan bar) hanya dengan satu baris kode.
 - Graph Objects (go): Memberikan fleksibilitas lebih bagi pengembang untuk membangun struktur grafik secara mendetail dan berlapis.
- Interaktivitas Bawaan:
 - Grafik Plotly memungkinkan pengguna untuk melakukan zoom, pan, serta melihat informasi detail melalui hover secara otomatis tanpa kode tambahan.
 - Sunburst Charts: Visualisasi data hierarkis (seperti bulan sebagai akar dan negara bagian tujuan sebagai cabang) dalam bentuk lingkaran konsentris yang dapat diklik untuk eksplorasi lebih dalam.
- Analisis Penerbangan:
 - Menggunakan dataset maskapai untuk memetakan hubungan antara waktu (bulan) dan distribusi geografis (negara bagian tujuan).
 - Inference: Memudahkan identifikasi pola frekuensi penerbangan tertinggi berdasarkan segmentasi waktu secara visual.

2. dash basics: html and core components => memperkenalkan cara mengubah visualisasi statis menjadi aplikasi web interaktif menggunakan framework Dash. Lab ini fokus pada pembangunan struktur dasar aplikasi (layout) menggunakan komponen HTML untuk teks dan struktur, serta komponen inti Dash (Core Components) untuk merender grafik interaktif dari Plotly secara langsung di browser.

Poin Utama Lab:

- Arsitektur Dash Layout:
 - `html.Div`: Berfungsi sebagai wadah utama (container) untuk membungkus seluruh elemen aplikasi.
 - `html.H1` & `html.P`: Digunakan untuk menambahkan elemen visual standar web seperti judul besar dan paragraf deskripsi dengan kontrol gaya CSS (warna, ukuran font, perataan teks).
 - `dcc.Graph`: Komponen inti yang menjembatani antara data di Python/Plotly dengan tampilan grafik di browser.
 - Integrasi Data & Visual:
 - Menggunakan dataset performa maskapai untuk menghitung proporsi grup jarak penerbangan (Distance Group).
 - Membuat grafik lingkaran (Pie Chart) menggunakan `plotly.express` yang kemudian dimasukkan ke dalam parameter `figure` pada komponen Dash.
 - Alur Kerja Pengembangan (IDE):
 - Menulis skrip Python (.py), menginstal dependensi via terminal, dan menjalankan server lokal untuk menghosting aplikasi web dashboard tersebut.
3. add interactivity: user input and callbacks => memperkenalkan "otak" dari aplikasi Dash, yaitu Callbacks. Lab ini berfokus pada cara menghubungkan input dari pengguna (seperti mengetikkan tahun) dengan pembaruan grafik secara otomatis (real-time) tanpa perlu memuat ulang halaman. Anda belajar menggunakan dekorator `@app.callback` untuk menangkap data dari komponen input dan mengirimkannya ke fungsi pemrosesan data sebelum akhirnya divisualisasikan kembali ke komponen output.

Poin Utama Lab:

- Mekanisme Callback:
 - Input: Mengambil properti `value` dari komponen `dcc.Input` (tempat pengguna memasukkan tahun).

- Output: Menargetkan properti figure dari komponen dcc.Graph untuk memperbarui tampilan visual.
 - Dekorator @app.callback: Berperan sebagai jembatan yang memberitahu Dash untuk menjalankan fungsi tertentu setiap kali nilai input berubah.
 - Pemrosesan Data Dinamis:
 - Fungsi callback menerima entered_year sebagai argumen.
 - Data difilter menggunakan Pandas berdasarkan tahun yang dimasukkan: `df = airline_data[airline_data['Year']==int(entered_year)]`.
 - Melakukan agregasi (seperti mean() untuk delay atau sum() untuk jumlah penerbangan) sebelum dikirim ke Plotly.
 - Visualisasi Interaktif:
 - Line Plot (Scatter): Menggunakan go.Scatter untuk melihat tren rata-rata keterlambatan per bulan.
 - Bar Chart (Plotly Express): Menggunakan px.bar untuk membandingkan jumlah penerbangan antar negara bagian tujuan.
4. dash components: multiple graphs & multi-output callbacks => mempelajari cara menyusun dashboard profesional dengan banyak grafik sekaligus dalam satu tampilan. Lab ini berfokus pada teknik penggunaan Flexbox (display: flex) untuk menata grafik berdampingan, serta penggunaan Multi-Output Callbacks yang memungkinkan satu input pengguna (tahun) memperbarui 5 grafik delay sekaligus secara sinkron.

Poin Utama Lab:

- Tata Letak (Layout) Multi-Segment:
 - Segmentasi Visual: Membagi dashboard menjadi tiga segmen utama menggunakan html.Div untuk menciptakan struktur yang rapi.
 - Side-by-Side Graphs: Menerapkan gaya `style={'display': 'flex'}` pada kontainer luar agar dua grafik (dcc.Graph) dapat tampil berjajar dalam satu baris, mengoptimalkan ruang layar.
- Multi-Output Callbacks:
 - List of Outputs: Mendefinisikan beberapa Output sekaligus di dalam dekorator @app.callback dalam bentuk list.
 - Sinkronisasi Data: Memastikan fungsi callback mengembalikan jumlah objek grafik (figures) yang sesuai dengan urutan daftar Output yang didefinisikan (dalam hal ini, 5 grafik).

- Fungsi Pendukung (Helper Function):
 - Memisahkan logika perhitungan data ke dalam fungsi khusus `compute_info` untuk menjaga kode tetap bersih dan efisien saat menangani agregasi data delay (Carrier, Weather, NAS, Security, dan Late Aircraft).

Module 5

1. Practice Assignment - Part 1: Analyzing Wildfire Activities in Australia. Tugas ini merupakan penerapan langsung dari teknik visualisasi yang telah Anda pelajari sebelumnya untuk menganalisis data riil (aktivitas kebakaran hutan).

Poin Utama Analisis:

- Korelasi dengan Seaborn (Scatter Plot):
 - Tujuan: Menganalisis hubungan antara tingkat kepercayaan data (Mean Confidence) dengan kekuatan radiasi api yang diestimasi (Mean Estimated Fire Radiative Power).
 - Wawasan: Grafik ini membantu peneliti memahami seberapa andal data sensor satelit saat mendeteksi api dengan intensitas panas tertentu dalam satuan Megawatt (MW).
- Visualisasi Geospasial dengan Folium:
 - Pemetaan Regional: Menandai tujuh wilayah utama di Australia (NSW, QL, SA, TA, VI, WA, NT) menggunakan koordinat geografis (Latitude & Longitude).
 - Fitur Interaktif: Penggunaan CircleMarker berwarna merah dengan isian biru memberikan tanda visual yang jelas pada peta yang berpusat di koordinat [-25, 135].
 - Feature Group: Mengelompokkan penanda wilayah agar peta tetap terorganisir dan interaktif dengan label pop-up untuk setiap singkatan wilayah.
- 2. Practice Assignment Part 2: Australia Wildfire Dashboard. Pada tahap ini, Anda menggabungkan semua keterampilan yang telah dipelajari untuk membangun aplikasi pemantauan kebakaran hutan Australia yang interaktif.

Komponen Utama Dashboard

Dashboard ini dirancang untuk memberikan wawasan mendalam mengenai aktivitas kebakaran berdasarkan wilayah dan waktu dengan fitur-fitur berikut:

- Sistem Input Ganda:

- Radio Items (region): Memungkinkan pengguna memilih wilayah Australia (seperti NSW, Victoria, dll.) secara horizontal menggunakan properti `inline=True`.
- Dropdown (year): Mengambil tahun unik dari dataset (2005–2020) menggunakan fungsi `df.Year.unique()` dari Pandas.
- Output Visual Dinamis:
 - Pie Chart (plot1): Menampilkan proporsi rata-rata bulanan area kebakaran yang diestimasi (Estimated Fire Area).
 - Bar Chart (plot2): Menampilkan rata-rata jumlah piksel kebakaran vegetasi (Count of Pixels) per bulan untuk melihat intensitas kebakaran.

Logika Callback (Mesin Dashboard)

Fungsi `reg_year_display` adalah inti dari interaktivitas ini:

- Filter Data: Fungsi ini menerima dua argumen (`input_region`, `input_year`) dan memfilter dataframe utama secara berjenjang.
 - Agregasi: Menggunakan `groupby('Month')` untuk menghitung nilai rata-rata (`mean()`) dari area kebakaran dan jumlah piksel.
 - Return Graph: Mengembalikan dua objek `dcc.Graph` ke dalam kontainer yang telah disiapkan di layout (ID `plot1` dan `plot2`).
3. Tugas visualisasi menggunakan Folium untuk menganalisis dampak resesi terhadap penjualan otomotif di berbagai kota/negara bagian. Tugas ini melengkapi kemahiran Anda dalam menggunakan peta tematik (Choropleth) untuk menyajikan data ekonomi secara geografis.

Poin Utama Analisis Geospasial:

- Penyaringan Data Spesifik: Fokus analisis dilakukan pada periode resesi (`Recession == 1`) untuk melihat bagaimana penurunan ekonomi berdampak pada volume penjualan otomotif di lokasi kantor perusahaan.
- Agregasi Penjualan: Menggunakan fungsi `groupby('City')` untuk menjumlahkan total penjualan (`Automobile_Sales`) guna menentukan intensitas warna pada peta.
- Pemetaan Choropleth: * GeoJSON: Menggunakan file `us-states.json` sebagai referensi batas wilayah geografis.
 - Skala Warna: Menerapkan palet `YlOrRd` (Yellow-Orange-Red), di mana warna yang lebih gelap menunjukkan area dengan volume penjualan yang lebih tinggi (atau dampak yang berbeda) selama resesi.

- Interaktivitas: Penambahan GeoJsonTooltip memungkinkan pengguna melihat nama wilayah saat mengarahkan kursor (hover), memberikan konteks instan pada data visual.

4. Final Assignment: Automobile Sales Statistics Dashboard Analysis

- Deskripsi Dashboard
 - Judul Utama: Dashboard Statistik Penjualan Otomotif Historis
 - Subjudul: Analisis Tren Penjualan Selama Periode Resesi dan Pertumbuhan Tahunan (1980 - 2013)
- Komponen Laporan (Fitur Dropdown)
 - Statistik Tahunan: Laporan ini menyajikan ringkasan kinerja penjualan, tren bulanan, dan pengeluaran iklan untuk tahun tertentu yang dipilih.
 - Statistik Periode Resesi: Laporan ini menganalisis dampak resesi terhadap volume penjualan, pangsa pasar berdasarkan tipe kendaraan, dan pengaruh tingkat pengangguran.
- Ringkasan Temuan dan Analisis Grafik
 - A. Analisis Statistik Periode Resesi:
 - Tren Penjualan: Terjadi fluktuasi signifikan pada rata-rata penjualan mobil selama masa resesi, dengan penurunan tajam pada kategori kendaraan eksekutif.
 - Pengeluaran Iklan: Selama resesi, alokasi anggaran iklan cenderung lebih besar pada kendaraan keluarga kecil dan menengah untuk mempertahankan pangsa pasar.
 - Dampak Pengangguran: Terdapat korelasi negatif yang jelas antara tingkat pengangguran dan rata-rata penjualan kendaraan di semua tipe tipe mobil.
 - B. Analisis Statistik Tahunan (Kondisi Normal):
 - Pertumbuhan Tahunan: Tren penjualan mobil menunjukkan pertumbuhan rata-rata yang stabil dari tahun ke tahun di luar periode resesi ekonomi.
 - Penjualan Bulanan: Volume penjualan tertinggi umumnya tercatat pada kuartal kedua, menunjukkan adanya pola musiman dalam pembelian kendaraan.

- Proporsi Kendaraan: Kendaraan bertipe keluarga tetap mendominasi total unit yang terjual dibandingkan tipe sports atau executive.
- Instruksi Penggunaan (Panduan Pengguna)
 - Gunakan menu tarik-turun (dropdown) di atas untuk memilih jenis laporan yang ingin ditampilkan.
 - Pilih tahun tertentu untuk mengaktifkan statistik tahunan secara mendalam.
 - Arahkan kursor pada grafik untuk melihat detail angka dan persentase di setiap kategori.
- Kesimpulan Strategis

"Dashboard ini memberikan gambaran strategis bagi XYZAutomotives untuk menyesuaikan strategi pemasaran dan inventaris berdasarkan kondisi ekonomi makro."

COURSE 9

Module 2

1. Practice Project: Simple Linear Regression for CO2 Emissions

Merupakan proyek fundamental Machine Learning yang menerapkan teknik pemodelan prediktif untuk mengestimasi emisi gas buang kendaraan. Proyek ini berfokus pada penggunaan variabel tunggal untuk memahami hubungan linier antara karakteristik teknis mesin dengan dampak lingkungan yang dihasilkan.

Poin Utama Proyek:

- Pemodelan dengan Scikit-Learn: Mengimplementasikan library `sklearn.linear_model` untuk membangun model regresi yang mampu menentukan garis kecocokan terbaik (line of best fit) melalui penghitungan parameter intersep (θ_0) dan koefisien (θ_1).
- Strategi Validasi Train/Test Split: Menerapkan pembagian dataset menjadi data latih dan data uji secara proporsional. Teknik ini krusial untuk mengevaluasi kemampuan generalisasi model terhadap data baru yang belum pernah dilihat sebelumnya (out-of-sample accuracy).
- Analisis Komparatif Fitur: Melakukan eksperimen perbandingan antara variabel prediktor. Hasil evaluasi menunjukkan bahwa variabel `FUELCONSUMPTION_COMB` memberikan performa prediksi yang lebih kuat dibandingkan `ENGINE_SIZE`.

- **Evaluasi Metrik Akurasi:**Menggunakan metrik statistik Mean Squared Error (MSE) untuk mengukur tingkat kesalahan kuadrat rata-rata. Penurunan nilai MSE pada fitur konsumsi bahan bakar mengonfirmasi akurasi model yang lebih tinggi dalam memprediksi emisi \$CO_2\$.
- **Visualisasi Regresi Linier:**Memanfaatkan Matplotlib untuk memplot distribusi data asli dan garis prediksi model. Visualisasi ini membantu dalam memverifikasi secara intuitif sejauh mana model linier dapat menangkap pola sebaran data yang sebenarnya.

2. Practice Project: Multiple Linear Regression for CO2 Emissions

Merupakan proyek pemodelan prediktif tingkat lanjut yang memperluas konsep regresi linier dengan melibatkan lebih dari satu variabel independen secara simultan. Proyek ini bertujuan untuk menangkap kompleksitas hubungan antara berbagai spesifikasi teknis kendaraan (seperti jumlah silinder, ukuran mesin, dan konsumsi bahan bakar) terhadap total emisi \$CO_2\$ yang dihasilkan.

Poin Utama Proyek:

- **Pemodelan Multivariat dengan Scikit-Learn:**Mengaplikasikan library sklearn untuk memetakan hubungan antara beberapa fitur input sekaligus. Model ini mampu menghitung bobot koefisien yang berbeda untuk setiap variabel, memberikan pemahaman tentang kontribusi relatif masing-masing fitur terhadap emisi.
- **Optimalisasi Prediksi Melalui Kombinasi Fitur:**Menggunakan variabel `ENGINE_SIZE`, `CYLINDERS`, dan `FUEL_CONSUMPTION_COMB` secara bersamaan sebagai input. Pendekatan ini terbukti lebih akurat dalam menjelaskan varians data dibandingkan hanya mengandalkan satu prediktor tunggal.
- **Evaluasi Residual dan Garis Kecocokan:**Menganalisis hasil prediksi menggunakan scatter plot pada data uji (test data) untuk memvisualisasikan sebaran emisi aktual terhadap garis regresi. Evaluasi ini dilakukan untuk mengidentifikasi apakah model telah berhasil meminimalkan jarak antara titik data asli dengan prediksi.
- **Analisis Koefisien Model:**Mengekstrak nilai koefisien dan intersep untuk membangun persamaan matematis regresi. Pemahaman mendalam pada tahap ini memungkinkan identifikasi faktor mana yang paling sensitif dalam meningkatkan kadar emisi kendaraan secara signifikan.

- Penyempurnaan Model Berkelanjutan: Mengkaji potensi peningkatan akurasi melalui eksplorasi fitur tambahan. Proyek ini memberikan dasar untuk memahami bahwa pemilihan variabel yang lebih kompleks dapat menurunkan tingkat error secara drastis dibandingkan model regresi linier sederhana.

3. Practice Project: Logistic Regression for Customer Churn Classification

Merupakan proyek klasifikasi Machine Learning yang bertujuan untuk memprediksi probabilitas pelanggan yang akan meninggalkan layanan (churn) pada perusahaan telekomunikasi. Proyek ini menerapkan algoritma regresi logistik untuk menghasilkan estimasi peluang diskrit berdasarkan perilaku dan demografi pelanggan.

Poin Utama Proyek:

- Implementasi Klasifikasi Biner: Menggunakan library Scikit-learn untuk membangun model regresi logistik. Berbeda dengan regresi linier, model ini memetakan variabel independen ke dalam fungsi sigmoid untuk menghasilkan output probabilitas antara 0 dan 1, yang sangat efektif untuk pengambilan keputusan klasifikasi.
- Pra-pemrosesan Data dan Skalasi Fitur: Menerapkan StandardScaler untuk menormalisasi dataset sehingga setiap fitur memiliki rata-rata nol dan varians satu. Tahap ini krusial dalam regresi logistik untuk memastikan algoritma optimasi (seperti liblinear) konvergen lebih cepat dan memberikan bobot yang adil pada setiap fitur.
- Optimasi Melalui Engineering Fitur: Melakukan serangkaian eksperimen dengan menambah atau menghapus variabel (seperti callcard, wireless, dan equip) untuk mengamati dampaknya terhadap performa model. Proses ini membantu dalam mengidentifikasi kombinasi fitur yang paling relevan dalam menjelaskan loyalitas pelanggan.
- Evaluasi Kinerja dengan Log Loss: Menggunakan metrik log_loss sebagai indikator utama akurasi probabilitas model. Analisis menunjukkan bahwa penambahan fitur yang informatif (seperti callcard dan wireless) secara konsisten menurunkan nilai log loss, yang berarti model menjadi lebih yakin dan akurat dalam prediksinya.
- Tuning Parameter Regularisasi: Mengatur parameter kekuatan regularisasi (C) dan pemilihan solver untuk mencegah overfitting. Hal ini memastikan model tetap stabil saat menghadapi data uji dan mampu menggeneralisasi pola perilaku pelanggan secara objektif.

Module 3

1. Practice Project: Multi-class Classification for Obesity Risk Prediction

Merupakan proyek pengembangan alur kerja (pipeline) Machine Learning yang bertujuan untuk mengklasifikasikan tingkat risiko obesitas individu ke dalam berbagai kategori (seperti Underweight, Normal Weight, Overweight, hingga Obesity Types). Proyek ini menekankan pada otomatisasi pemrosesan data heterogen untuk menghasilkan model klasifikasi multinomial yang stabil.

Poin Utama Proyek:

- Otomatisasi Alur Kerja (Pipeline Engineering): Mengembangkan fungsi terintegrasi `obesity_risk_pipeline` yang merangkum seluruh siklus Data Science, mulai dari pemuatan data, pra-pemrosesan, hingga evaluasi. Pendekatan ini menjamin konsistensi transformasi data antara fase pelatihan dan pengujian.
- Transformasi Data Heterogen: Mengimplementasikan teknik pra-pemrosesan ganda: `StandardScaler` untuk menormalisasi fitur numerik kontinu dan `OneHotEncoder` untuk mengonversi variabel kategorikal menjadi format biner. Hal ini memungkinkan algoritma matematis menangani berbagai tipe data secara simultan tanpa bias skala.
- Klasifikasi Multinomial: Menerapkan model Logistic Regression dengan parameter `multi_class='multinomial'`. Teknik ini menggunakan fungsi Softmax untuk memprediksi probabilitas setiap kelas target secara kolektif, yang jauh lebih efisien untuk masalah dengan lebih dari dua kategori label.
- Strategi Validasi Terstratifikasi: Menggunakan teknik `stratify=y` saat melakukan train-test split. Strategi ini sangat krusial dalam klasifikasi multi-kelas untuk memastikan bahwa proporsi setiap kategori obesitas tetap seimbang di dalam data latih maupun data uji, guna menghindari bias pada kelas minoritas.
- Evaluasi Performa Model: Mengukur keberhasilan model menggunakan metrik akurasi guna menentukan persentase prediksi yang tepat di seluruh spektrum kategori risiko. Eksperimen ini memberikan fondasi bagi pengembangan model diagnostik yang lebih kompleks di sektor kesehatan digital.

2. Practice Project: Decision Tree Classification for Drug Prescription

Merupakan proyek pengembangan model klasifikasi non-parametrik yang bertujuan untuk merekomendasikan jenis obat yang tepat bagi pasien berdasarkan karakteristik medis mereka. Proyek ini mengeksplorasi bagaimana algoritma pohon keputusan

mentransformasi data klinis menjadi sekumpulan aturan logika yang intuitif dan dapat diinterpretasikan.

Poin Utama Proyek:

- Penerapan Algoritma Pohon Keputusan: Menggunakan library Scikit-learn untuk membangun model DecisionTreeClassifier. Algoritma ini bekerja dengan membagi dataset secara rekursif berdasarkan fitur yang paling informatif, menciptakan struktur hirarki yang memetakan kondisi pasien ke kategori obat tertentu (Drug A, B, C, X, atau Y).
- Optimasi Pemisahan dengan Kriteria Entropy: Menggunakan kriteria Entropy dan Information Gain untuk menentukan atribut mana yang paling efektif dalam mengurangi ketidakpastian (impurity) pada setiap node. Teknik ini memastikan bahwa setiap percabangan dalam pohon memberikan pemisahan kelas yang paling murni.
- Interpretasi Logika Model: Menganalisis kriteria keputusan dengan menelusuri jalur dari root node hingga leaf node. Kemampuan model untuk divisualisasikan memungkinkan tenaga medis memahami alasan logis di balik setiap prediksi, seperti pengaruh kadar Kalium (K^+) atau rasio Na^+/K^+ terhadap pemilihan jenis obat.
- Kendali Kompleksitas melalui Hyperparameter Tuning: Melakukan eksperimen dengan membatasi kedalaman pohon (max_depth). Analisis menunjukkan bagaimana pengurangan kedalaman dapat mencegah overfitting, namun jika terlalu dangkal (misalnya $\text{max_depth} = 3$), model berisiko mengalami underfitting yang ditandai dengan penurunan akurasi karena gagal menangkap kompleksitas data yang lebih dalam.
- Evaluasi Kinerja Klinis: Mengukur efektivitas model menggunakan metrik akurasi untuk memastikan keandalan rekomendasi obat. Proyek ini mendemonstrasikan bagaimana otomatisasi diagnosa berbasis data dapat mendukung pengambilan keputusan klinis yang lebih cepat dan konsisten.

3. Practice Project: Regression Trees for Continuous Value Prediction

Merupakan proyek pengembangan model regresi non-linier yang menggunakan struktur pohon keputusan untuk memprediksi variabel target kontinu. Proyek ini menekankan pada pentingnya pengendalian kompleksitas model melalui pengaturan hyperparameter untuk mencapai keseimbangan antara bias dan varians dalam estimasi nilai numerik.

Poin Utama Proyek:

- Implementasi Regresi Berbasis Pohon: Menggunakan Decision Tree
Regressor dari library Scikit-learn untuk memetakan hubungan non-linier antara fitur input dan output kontinu. Berbeda dengan regresi linier, model ini membagi ruang fitur menjadi wilayah-wilayah lokal dan memberikan prediksi berdasarkan nilai rata-rata sampel pada setiap leaf node.
 - Pengendalian Overfitting melalui Max Depth: Melakukan eksperimen krusial dengan membatasi kedalaman pohon ($\text{max_depth}=4$). Teknik ini berfungsi sebagai bentuk pemangkasan (pruning) dini yang mencegah pohon tumbuh terlalu kompleks dan menangkap noise dari data latih, sehingga meningkatkan kemampuan model dalam menggeneralisasi data baru.
 - Evaluasi Performa dengan MSE dan R^2 Score: Menggunakan Mean Squared Error (MSE) untuk mengukur rata-rata kuadrat kesalahan prediksi. Analisis menunjukkan bahwa dengan kedalaman yang tepat, nilai MSE menurun secara signifikan, menandakan peningkatan presisi dalam estimasi nilai target.
 - Analisis Koefisien Determinasi (R^2): Mengevaluasi skor R^2 untuk menentukan sejauh mana varians dari variabel target dapat dijelaskan oleh model. Hasil eksperimen membuktikan bahwa model dengan kedalaman terbatas ($\text{max_depth}=4$) menghasilkan skor R^2 yang lebih tinggi (mendekati 1), menunjukkan kesesuaian (fit) yang lebih baik terhadap dataset dibandingkan pohon yang terlalu dalam.
 - Optimalisasi Struktur Model: Menemukan titik optimal dalam arsitektur pohon di mana model cukup kompleks untuk mempelajari pola data namun cukup sederhana untuk menghindari kesalahan prediksi pada data uji. Proyek ini mendemonstrasikan bahwa hyperparameter tuning yang tepat sering kali lebih penting daripada kompleksitas model itu sendiri.
4. Practice Project: Credit Card Fraud Detection using Decision Trees and SVM
- Merupakan proyek deteksi anomali pada transaksi keuangan yang membandingkan dua arsitektur algoritma Machine Learning yang berbeda: Decision Trees dan Support Vector Machines (SVM). Proyek ini bertujuan untuk membangun model klasifikasi yang mampu membedakan transaksi sah dari aktivitas penipuan (fraud) dengan akurasi tinggi pada dataset yang memiliki dimensi fitur beragam.
- Poin Utama Proyek:**
- Komparasi Algoritma Klasifikasi: Menerapkan dua pendekatan yang berbeda untuk mendeteksi kecurangan. Decision Trees digunakan sebagai model berbasis

aturan (rule-based) yang mudah diinterpretasikan, sementara SVM digunakan untuk mencari hyperplane optimal yang memisahkan kelas transaksi dalam ruang dimensi tinggi.

- Optimalisasi SVM melalui Dimensi Fitur: Menemukan bahwa SVM menunjukkan performa yang lebih kompetitif saat bekerja dengan jumlah fitur yang lebih besar. Hal ini menegaskan karakteristik SVM yang membutuhkan dimensionalitas fitur yang memadai untuk menciptakan batas keputusan (decision boundary) yang efisien dan presisi.
- Efektivitas Seleksi Fitur pada Decision Trees: Mengidentifikasi bahwa model Decision Trees justru mendapatkan keuntungan signifikan dari seleksi fitur (feature selection). Dengan menyederhanakan input hanya pada variabel yang paling informatif, Decision Trees mampu menghasilkan model yang lebih akurat dan terhindar dari overfitting pada noise data.
- Evaluasi Performa dengan Metrik ROC-AUC: Menggunakan metrik Receiver Operating Characteristic - Area Under Curve (ROC-AUC) sebagai indikator utama keberhasilan. ROC-AUC memberikan gambaran objektif mengenai kemampuan model dalam membedakan kelas positif (fraud) dan negatif di berbagai ambang batas probabilitas, yang sangat krusial pada kasus data tidak seimbang (imbalanced data) seperti transaksi kartu kredit.
- Analisis Geometri Keputusan: Menarik inferensi strategis bahwa pemilihan algoritma harus disesuaikan dengan struktur data: Decision Trees unggul dalam hal transparansi dan efisiensi pada fitur terbatas, sedangkan SVM unggul dalam menangani kompleksitas fitur yang lebih luas untuk mencapai pemisahan kelas yang lebih tegas.

5. Practice Project: K-Nearest Neighbors Classifier for Customer Segmentation

Merupakan proyek klasifikasi Machine Learning berbasis instans (instance-based learning) yang bertujuan untuk memprediksi kategori pelanggan berdasarkan kemiripan karakteristik individu. Proyek ini menekankan pada pentingnya normalisasi data dan pemilihan parameter optimal dalam algoritma yang mengandalkan metrik jarak untuk menentukan klasifikasi.

Poin Utama Proyek:

- Implementasi Algoritma Berbasis Jarak: Menggunakan library Scikit-learn untuk membangun model KNeighborsClassifier. Algoritma ini bekerja dengan prinsip

memprediksi label target suatu titik data baru berdasarkan mayoritas kelas dari tetangga terdekatnya dalam ruang fitur multidimensi.

- Standarisasi Data untuk Akurasi Metrik Jarak: Menerapkan teknik pra-pemrosesan data menggunakan StandardScaler. Karena KNN sangat sensitif terhadap skala fitur (misalnya, variabel pendapatan memiliki rentang yang jauh lebih besar daripada usia), normalisasi menjadi krusial agar metrik jarak (seperti Euclidean distance) dapat memberikan bobot yang adil pada setiap atribut.
- Optimasi Parameter K (Hyperparameter Tuning): Melakukan eksperimen untuk menentukan nilai tetangga (K) yang paling optimal. Proses ini melibatkan pengujian berbagai nilai K untuk menemukan titik keseimbangan di mana model memiliki akurasi tertinggi tanpa mengalami underfitting (K terlalu besar) atau overfitting terhadap noise (K terlalu kecil).
- Evaluasi Performa melalui Akurasi Validasi: Mengukur keberhasilan model menggunakan metrik akurasi pada data uji. Analisis ini membantu dalam memahami sejauh mana kemiripan perilaku pelanggan di masa lalu dapat digunakan sebagai indikator yang andal untuk mengklasifikasikan pelanggan baru ke dalam segmen yang tepat.
- Aplikasi Klasifikasi Dunia Nyata: Mendemonstrasikan efektivitas KNN dalam menangani masalah klasifikasi multi-kelas pada sektor jasa. Proyek ini memberikan fondasi bagi sistem rekomendasi dan strategi pemasaran terarah yang mengandalkan pengelompokan profil pelanggan yang serupa secara otomatis.

6. Practice Project: Comparative Analysis of Random Forest and XGBoost Regression
- Merupakan proyek analisis tingkat lanjut yang membandingkan dua algoritma Ensemble Learning terpopuler untuk tugas regresi. Proyek ini mengevaluasi perbedaan mekanisme antara teknik Bagging (Random Forest) dan Boosting (XGBoost) dalam memprediksi nilai kontinu serta bagaimana masing-masing model menangani batasan distribusi data.

Poin Utama Proyek:

- Implementasi Arsitektur Ensemble: Menggunakan RandomForestRegressor dan XGBoost untuk membangun model prediktif. Proyek ini mendemonstrasikan kekuatan penggabungan banyak pohon keputusan untuk meningkatkan stabilitas dan akurasi dibandingkan penggunaan model pohon tunggal.

- **Komparasi Mekanisme Bagging vs. Boosting:** Menganalisis perbedaan fundamental di mana Random Forest membangun pohon secara paralel untuk mengurangi varians, sementara XGBoost membangun pohon secara sekuensial guna memperbaiki kesalahan dari pohon sebelumnya (residual) untuk mengurangi bias.
- **Analisis Batas Distribusi (Boundary Behavior):** Mengidentifikasi fenomena menarik di mana Random Forest cenderung "menghormati" batas atas nilai target dalam dataset, sedangkan XGBoost memiliki kecenderungan untuk melakukan overshoot atau memprediksi nilai yang melampaui batas maksimum historis. Hal ini memberikan wawasan krusial dalam pemilihan model berdasarkan karakteristik rentang data.
- **Visualisasi Performa Komparatif:** Mengembangkan grafik sebaran (scatter plots) untuk memetakan nilai aktual terhadap nilai prediksi. Penggunaan garis referensi model sempurna dan batas standar deviasi (± 1 Std Dev) memungkinkan evaluasi visual yang presisi mengenai tingkat kesalahan dan reliabilitas kedua model.
- **Evaluasi Generalisasi Model:** Menemukan bahwa kedua model memberikan hasil yang sangat baik, dengan mayoritas prediksi berada dalam rentang standar deviasi target. Proyek ini membuktikan bahwa meskipun kedua model berperforma tinggi, pemahaman tentang bagaimana mereka menangani ekstremitas data sangat penting untuk implementasi di dunia nyata.

Module 4

1. Practice Project: K-means Clustering for Customer Segmentation

Merupakan proyek analisis data eksploratif menggunakan algoritma Unsupervised Learning untuk mengidentifikasi pola tersembunyi dalam data demografi pelanggan. Proyek ini bertujuan untuk melakukan partisi pelanggan ke dalam kelompok-kelompok eksklusif guna mendukung strategi pemasaran berbasis profil perilaku dan ekonomi.

Poin Utama Proyek:

- **Implementasi Algoritma Clustering K-means:** Menggunakan library Scikit-learn untuk mengelompokkan data ke dalam sejumlah K kluster yang telah ditentukan (dalam kasus ini $K=3$). Algoritma ini bekerja dengan meminimalkan jarak intra-cluster (inersia) untuk memastikan setiap individu dalam satu kelompok memiliki kemiripan karakteristik yang maksimal.

- Visualisasi Multidimensi (3D Scatter Plot): Mengembangkan plot sebaran 3D interaktif menggunakan Plotly untuk memetakan hubungan antara variabel Education, Age, dan Income. Representasi spasial ini memberikan pemahaman mendalam tentang bagaimana batasan kluster terbentuk di ruang fitur yang lebih kompleks dibandingkan visualisasi 2D standar.
- Analisis Profiling Kelompok (Customer Profiling): Melakukan interpretasi data pasca-klasterisasi untuk mendefinisikan identitas setiap kelompok. Berdasarkan observasi, pelanggan berhasil dipisahkan menjadi tiga profil strategis:
 - Kluster 1: Late Career, Affluent, and Educated (Pendapatan tinggi, mapan secara usia dan pendidikan).
 - Kluster 2: Mid Career and Middle Income (Kelas menengah dengan progres karir moderat).
 - Kluster 3: Early Career and Low Income (Individu muda dengan pendapatan awal).
- Eksplorasi Hubungan Variabel melalui Pairwise Plot: Memanfaatkan Seaborn pairplot dengan pemetaan warna (hue) berdasarkan label kluster untuk meninjau korelasi antar semua pasangan fitur sekaligus. Teknik ini membantu memvalidasi efektivitas pemisahan kluster dan distribusi data menggunakan estimasi kepadatan kernel (KDE).
- Aplikasi Strategis dalam Bisnis: Mendemonstrasikan bagaimana teknik segmentasi otomatis dapat mengonversi data mentah menjadi wawasan bisnis yang dapat ditindaklanjuti. Hasil pengelompokan ini memungkinkan perusahaan untuk menyesuaikan kampanye produk dan komunikasi pemasaran yang berbeda secara spesifik untuk setiap segmen pelanggan.

2. Practice Project: Comparative Analysis of Density-Based Clustering (DBSCAN vs. HDBSCAN)

Merupakan proyek analisis data geospasial tingkat lanjut yang menerapkan algoritma pengelompokan berbasis kepadatan untuk memetakan lokasi museum di seluruh wilayah Kanada. Proyek ini mengevaluasi perbedaan antara teknik pemisahan densitas statis (DBSCAN) dan hierarkis (HDBSCAN) dalam menangani data lokasi nyata yang memiliki variasi kepadatan tidak seragam.

Poin Utama Proyek:

- Implementasi Algoritma Berbasis Kepadatan: Menggunakan library Scikit-learn untuk mengimplementasikan model DBSCAN dan HDBSCAN. Berbeda dengan K-means, algoritma ini tidak memerlukan penentuan jumlah kluster di awal dan mampu mengidentifikasi noise (data pencilan) yang tidak termasuk dalam kelompok mana pun secara otomatis.
 - Analisis Klasterisasi Hierarkis (HDBSCAN): Memanfaatkan algoritma HDBSCAN untuk menangkap variasi kepadatan yang berbeda di seluruh dataset. HDBSCAN terbukti lebih unggul dalam mengidentifikasi kluster dengan ukuran yang lebih beragam dan mampu menangani sebaran data yang memiliki tingkat kerapatan beragam secara dinamis dibandingkan parameter tetap pada DBSCAN.
 - Penanganan Noise dan Pencilan: Mengidentifikasi titik-titik data yang tidak memenuhi kriteria kepadatan sebagai noise. Analisis menunjukkan bahwa meskipun HDBSCAN mungkin mengidentifikasi lebih banyak titik sebagai noise, algoritma ini memberikan representasi yang lebih akurat mengenai struktur kluster yang sebenarnya di wilayah dengan kepadatan populasi yang bervariasi.
 - Visualisasi Geospasial Interaktif: Memetakan hasil klasterisasi ke dalam peta dasar (basemap) Kanada menggunakan koordinat geografis yang telah diskalakan. Visualisasi ini memungkinkan identifikasi lokasi museum secara intuitif berdasarkan kedekatan spasial, membantu pengguna memahami bagaimana museum-museum tersebut berkelompok di area metropolitan dibandingkan area terpencil.
 - Evaluasi Performa Komparatif: Membandingkan efektivitas kedua model dalam mengelompokkan data StatCan. Hasil akhir memberikan wawasan bahwa HDBSCAN memberikan partisi yang lebih halus dan mampu mengenali pola hierarkis dalam data geospasial, yang sangat krusial untuk perencanaan tata kota atau analisis distribusi fasilitas publik.
3. Practice Project: Principal Component Analysis (PCA) for Dimensionality Reduction
- Merupakan proyek optimasi dataset menggunakan teknik pembelajaran tanpa pengawasan (unsupervised learning) untuk menyederhanakan kompleksitas data tanpa kehilangan informasi esensial. Proyek ini berfokus pada transformasi fitur dari ruang dimensi tinggi ke dalam komponen utama (principal components) guna meningkatkan efisiensi komputasi dan mengurangi gangguan (noise) pada model.

Poin Utama Proyek:

- Proyeksi Data ke Sumbu Utama: Menggunakan library Scikit-learn untuk mengimplementasikan algoritma PCA guna memutar dan memproyeksikan data ke arah varians maksimum. Proses ini menghasilkan koordinat baru yang tidak saling berkorelasi (orthogonal), yang disebut sebagai Komponen Utama (PC1, PC2, dst.).
 - Reduksi Dimensionalitas Ruang Fitur: Menerapkan teknik kompresi data dengan mempertahankan hanya komponen yang memiliki kontribusi varians signifikan. Teknik ini sangat krusial dalam menangani curse of dimensionality, mempercepat waktu pelatihan model, dan mempermudah visualisasi data yang sebelumnya mustahil dilihat dalam ruang multidimensi.
 - Analisis Rasio Varians yang Dijelaskan (Explained Variance): Mengevaluasi kepentingan relatif dari setiap komponen utama melalui metrik `explained_variance_ratio_`. Dengan memplot nilai ini, dapat diidentifikasi berapa banyak informasi yang dipertahankan oleh setiap komponen, membantu praktisi dalam menentukan jumlah dimensi optimal yang harus dipertahankan.
 - Visualisasi Varians Kumulatif: Mengembangkan grafik gabungan antara bar chart untuk varians individu dan step plot untuk varians kumulatif. Garis putus-putus merah (kumulatif) berfungsi sebagai indikator strategis untuk menentukan ambang batas informasi (misalnya mempertahankan 95% varians) yang diperlukan untuk merepresentasikan dataset asli secara akurat.
 - Reduksi Noise dan Penekanan Fitur Utama: Menggunakan PCA sebagai alat penyaringan data di mana komponen dengan varians rendah (yang sering kali merupakan representasi dari noise) dibuang. Proyek ini mendemonstrasikan bahwa dengan mengabaikan komponen minor, model akhir dapat menjadi lebih stabil dan memiliki performa generalisasi yang lebih baik pada data baru.
4. Practice Project: Comparative Analysis of t-SNE, UMAP, and PCA for Manifold Learning
- Merupakan proyek analisis tingkat lanjut yang membandingkan berbagai algoritma reduksi dimensi untuk memvisualisasikan struktur data kompleks dalam ruang berdimensi rendah. Proyek ini mengevaluasi efektivitas teknik linier tradisional (PCA) terhadap algoritma pembelajaran manifold non-linier modern (t-SNE dan UMAP) dalam mempertahankan kepadatan dan jarak antar kluster data.

Poin Utama Proyek:

- Implementasi Algoritma Visualisasi Non-Linier: Mengaplikasikan t-SNE (t-Distributed Stochastic Neighbor Embedding) dan UMAP (Uniform Manifold Approximation and Projection) untuk memetakan dataset dimensi tinggi ke dalam ruang 2D. Eksperimen ini fokus pada kemampuan algoritma dalam menjaga struktur lokal dan global dari kumpulan data (blobs).
- Benchmarking dengan PCA: Menggunakan Principal Component Analysis (PCA) sebagai baseline perbandingan. Analisis menunjukkan bahwa untuk dataset tertentu, PCA mampu mempertahankan kepadatan relatif dan pemisahan antar kluster secara lebih konsisten dibandingkan metode non-linier yang lebih kompleks.
- Analisis Retensi Struktur Data: Mengevaluasi bagaimana setiap algoritma menangani jarak antar kluster. Hasil observasi mengonfirmasi bahwa PCA sangat setia dalam menjaga derajat pemisahan asli, sementara t-SNE dan UMAP terkadang dapat mendistorsi jarak global demi penekanan pada struktur lokal.
- Evaluasi Efisiensi Komputasi: Melakukan perbandingan waktu eksekusi antar algoritma. Temuan teknis menunjukkan bahwa PCA dan t-SNE membutuhkan waktu pemrosesan yang jauh lebih singkat dibandingkan UMAP, memberikan wawasan penting mengenai trade-off antara kompleksitas algoritma dan sumber daya komputasi.
- Kritik Pemilihan Model (Principle of Parsimony): Menarik kesimpulan strategis bahwa algoritma yang lebih canggih tidak selalu memberikan hasil yang lebih baik. Proyek ini menekankan pentingnya memulai analisis dengan metode yang lebih sederhana (PCA) sebelum beralih ke algoritma manifold yang lebih berat, guna menghindari kompleksitas yang tidak perlu jika hasil dasar sudah optimal.

Module 5

1. Practice Project: Performance Evaluation and Robustness Testing in Classification

Merupakan proyek analisis komparatif untuk menilai efektivitas model klasifikasi dalam mendiagnosis data medis (seperti deteksi massa jinak atau ganas). Proyek ini berfokus pada validasi model melalui metrik statistik mendalam serta pengujian ketahanan model terhadap gangguan data (noise).

Poin Utama Proyek:

- Implementasi Evaluasi Multi-Model: Membangun dan membandingkan model Support Vector Machine (SVM) dan K-Nearest Neighbors (KNN) pada dataset

dunia nyata. Proyek ini menekankan pada penggunaan Confusion Matrix untuk membedah performa model melampaui sekadar angka akurasi, guna memahami distribusi False Positives dan False Negatives.

- Analisis Generalisasi dan Overfitting: Melakukan audit terhadap selisih akurasi antara data latih (training) dan data uji (testing). Hasil evaluasi menunjukkan bahwa model SVM memiliki performa yang sangat stabil (akurasi ~97% pada kedua fase), sementara KNN menunjukkan indikasi overfitting ringan dengan penurunan akurasi sebesar 2% pada data uji.
- Identifikasi Data Leakage: Mengkaji potensi kesalahan metodologis seperti Data Leakage yang timbul akibat normalisasi dataset secara keseluruhan sebelum pembagian data (splitting). Kesadaran teknis ini sangat penting untuk memastikan integritas model dan mencegah estimasi akurasi yang terlalu optimis secara semu.
- Uji Ketahanan terhadap Noise (Robustness Testing): Mensimulasikan kesalahan pengukuran di dunia nyata dengan menambahkan gangguan acak (Gaussian random noise) ke dalam fitur-fitur dataset. Eksperimen ini bertujuan untuk mengevaluasi sejauh mana model tetap mampu memberikan prediksi yang akurat meskipun bekerja dengan data yang kurang sempurna.
- Sintesis dan Pemilihan Model: Menarik kesimpulan bahwa SVM tidak hanya menghasilkan akurasi yang lebih tinggi, tetapi juga menunjukkan konsistensi yang lebih meyakinkan antara data latih dan uji dibandingkan KNN. Proyek ini membuktikan bahwa stabilitas model terhadap data baru adalah indikator kualitas yang sama pentingnya dengan nilai akurasi itu sendiri.

2. Practice Project: Random Forest Regression for California Housing Prediction

Merupakan proyek pemodelan prediktif yang menggunakan algoritma ensemble learning untuk mengestimasi nilai median harga rumah. Proyek ini menekankan pada kekuatan model berbasis pohon dalam menangani data dunia nyata yang kompleks, serta pentingnya interpretasi fitur dan visualisasi hasil untuk mendeteksi bias pada data.

Poin Utama Proyek:

- Implementasi Regresi Ensemble yang Kokoh: Membangun model Random Forest Regressor menggunakan dataset California Housing. Berbeda dengan regresi linier, algoritma ini terbukti jauh lebih tangguh terhadap outliers dan distribusi data yang miring (skewed) karena tidak bergantung pada asumsi normalitas data.
- Analisis Pentingnya Fitur (Feature Importance): Mengekstrak dan mengevaluasi kontribusi setiap atribut (seperti lokasi geografis, pendapatan rata-rata, dan

jumlah kamar) dalam menentukan harga rumah. Kemampuan ini memungkinkan praktisi untuk memahami faktor dominan yang mempengaruhi nilai pasar secara transparan.

- Agnostis terhadap Skala Data: Memanfaatkan keunggulan teknis pohon keputusan yang tidak memerlukan standarisasi atau normalisasi data (tidak seperti KNN atau SVM). Hal ini menyederhanakan alur kerja pra-pemrosesan tanpa mengurangi akurasi prediksi model.
- Identifikasi dan Dampak Data Terpotong (Clipped Values): Mendeteksi keberadaan nilai yang terpotong pada batas tertentu (misalnya harga maksimum yang dibatasi) melalui visualisasi. Analisis menunjukkan bahwa data clipped ini dapat menyesatkan metrik evaluasi dan membiasakan prediksi karena hilangnya variabilitas asli pada titik ekstrim tersebut.
- Evaluasi Melalui Visualisasi Kritis: Menerapkan teknik visualisasi untuk membandingkan nilai aktual terhadap prediksi. Langkah ini krusial untuk mengidentifikasi pola kesalahan sistematis yang mungkin tidak tertangkap hanya melalui angka metrik tunggal, sehingga memastikan model benar-benar menangkap varians data yang relevan.'

3. Practice Project: Performance Evaluation and Geometric Constraints of K-means Clustering

Merupakan proyek eksperimental menggunakan data sintetis untuk menguji efektivitas dan keterbatasan algoritma K-means dalam mengenali berbagai struktur data. Proyek ini memfokuskan pada perbandingan antara hasil pengelompokan otomatis dengan label kelas yang sebenarnya (ground truth) untuk memahami asumsi geometris algoritma.

Poin Utama Proyek:

- Implementasi Klasterisasi pada Data Sintetis: Menggunakan teknik pembuatan data buatan untuk mensimulasikan berbagai bentuk distribusi kelas (seperti bentuk sferis dan linear). Hal ini memungkinkan evaluasi yang objektif karena jawaban yang benar (ground truth) sudah diketahui sebelumnya.
- Analisis Geometri Voronoi: Mengidentifikasi batasan algoritma melalui visualisasi garis wilayah Voronoi. Eksperimen menunjukkan bahwa K-means secara inheren mengasumsi klaster berbentuk bola (spherical) dan membagi ruang berdasarkan jarak euklidian ke pusat massa (centroid), yang menyebabkan kegagalan dalam menangkap pola kelas yang memanjang atau linear.

- Evaluasi melalui Silhouette Score: Menerapkan metrik Silhouette Score untuk mengukur kualitas pemisahan kluster. Temuan menarik menunjukkan bahwa skor Silhouette terkadang lebih tinggi pada hasil K-means dibandingkan pada label kelas asli; hal ini dikarenakan algoritma memaksa pemisahan yang bersih bahkan pada area di mana kelas sebenarnya saling tumpang tindih (overlap).
- Identifikasi Kelemahan Berbasis Kepadatan: Menemukan bahwa K-means tidak mampu memperhitungkan variasi kepadatan poin atau kontinuitas data. Poin-poin pada kelas linear sering kali salah diklasifikasikan ke dalam kluster sferis terdekat karena algoritma hanya berfokus pada minimalisasi inersia, bukan pada struktur kepadatan data.
- Sintesis Strategi Algoritma Alternatif: Menarik kesimpulan teknis bahwa untuk dataset dengan struktur non-linear atau kepadatan yang bervariasi, algoritma berbasis kepadatan seperti DBSCAN jauh lebih unggul. Proyek ini menekankan pentingnya kreativitas dalam memilih algoritma yang sesuai dengan karakteristik geometri data di dunia nyata, di mana label kelas asli tidak tersedia.

4. Practice Project: Regularization Techniques for Robust Linear Modeling

Merupakan proyek optimasi model regresi yang mengeksplorasi penggunaan teknik regularisasi untuk mengatasi masalah overfitting dan gangguan noise pada data. Proyek ini membandingkan efektivitas regresi Linier standar dengan teknik Ridge dan Lasso dalam menangani data yang mengandung outliers serta melakukan seleksi fitur secara otomatis.

Poin Utama Proyek:

- Implementasi Perbandingan Teknik Regularisasi: Menerapkan tiga metode pemodelan secara simultan: Linear Regression (tanpa penalti), Ridge Regression (penalti L_2), dan Lasso Regression (penalti L_1). Eksperimen ini bertujuan untuk memahami bagaimana penambahan fungsi penalti pada koefisien dapat menstabilkan model saat menghadapi data yang kompleks.
- Analisis Ketahanan terhadap Noise dan Outliers: Mengevaluasi performa model pada dataset yang mengandung gangguan (noisy data) dan pencilan (outliers). Teknik regularisasi (terutama Ridge) terbukti lebih mampu meredam pengaruh ekstrem dari outliers dibandingkan regresi linier standar, sehingga menghasilkan garis prediksi yang lebih stabil dan dapat digeneralisasi.
- Seleksi Fitur Otomatis melalui Lasso: Memanfaatkan karakteristik unik dari Lasso Regression yang dapat memaksa koefisien fitur yang kurang relevan menjadi nol.

Proses ini secara efektif berfungsi sebagai mekanisme seleksi fitur otomatis, menyederhanakan model regresi berganda dengan hanya mempertahankan variabel yang paling berpengaruh terhadap target.

- **Evaluasi Visual melalui Plot Komparatif:** Mengembangkan visualisasi matriks (2x3) yang membandingkan nilai aktual vs prediksi serta plot garis "Ideal". Visualisasi ini memudahkan identifikasi sejauh mana setiap model menyimpang dari nilai sebenarnya, di mana model dengan regularisasi biasanya menunjukkan deviasi yang lebih rendah pada data uji dibandingkan model linier murni.
- **Sintesis Strategi Pemodelan:** Menarik kesimpulan teknis bahwa penggunaan regularisasi adalah langkah esensial dalam alur kerja Machine Learning untuk mencegah model "menghafal" noise. Proyek ini memberikan dasar untuk menentukan kapan harus menggunakan penalti L_1 (untuk penyederhanaan fitur) atau penalti L_2 (untuk menjaga semua fitur namun dengan bobot yang diperkecil).

5. Practice Project: Automated Machine Learning Pipelines and Hyperparameter Optimization

Merupakan proyek pengembangan alur kerja Machine Learning tingkat lanjut yang mengintegrasikan seluruh tahap pemrosesan data dan pemodelan ke dalam satu kesatuan arsitektur otomatis. Proyek ini menekankan pada penggunaan teknik pencarian sistematis untuk menemukan kombinasi parameter model terbaik guna mencapai performa klasifikasi yang optimal.

Poin Utama Proyek:

- **Konstruksi Pipeline Terintegrasi:** Menggunakan Pipeline dari Scikit-learn untuk merangkai tahap pra-pemrosesan (seperti standarisasi fitur) dan tahap pemodelan (seperti K-Nearest Neighbors) ke dalam satu objek tunggal. Pendekatan ini mencegah kebocoran data (data leakage) dan memastikan konsistensi transformasi data antara fase pelatihan dan pengujian.
- **Optimasi Hyperparameter dengan GridSearchCV:** Mengimplementasikan GridSearchCV untuk melakukan pencarian otomatis terhadap parameter terbaik (seperti jumlah tetangga K pada KNN). Proses ini melibatkan pengujian ribuan kombinasi parameter secara sistematis untuk mengidentifikasi konfigurasi yang menghasilkan akurasi tertinggi.
- **Validasi Silang (Cross-Validation):** Menerapkan teknik k-fold cross-validation selama proses pencarian grid. Teknik ini memastikan bahwa evaluasi parameter

dilakukan secara objektif pada berbagai subset data, sehingga model yang dihasilkan memiliki kemampuan generalisasi yang kuat terhadap data baru.

- Analisis Diagnostik melalui Confusion Matrix: Mengevaluasi performa model terbaik menggunakan matriks kebingungan (confusion matrix) yang divisualisasikan dengan Seaborn. Analisis mendalam menunjukkan presisi yang mengesankan, di mana model hanya melakukan kesalahan minimal dalam membedakan kelas target yang memiliki karakteristik serupa (seperti antara spesies Versicolor dan Virginica).
- Ekstraksi Wawasan dan Skalabilitas: Mendemonstrasikan cara mengekstrak fitur paling berpengaruh dari pipeline yang telah dilatih. Metodologi ini membekali praktisi dengan kemampuan untuk membangun model klasifikasi yang canggih dari nol, yang siap untuk diterapkan pada skala industri dengan kode yang lebih bersih dan mudah dipelihara.

Module 6

1. Practice Project: Titanic Survival Prediction & Model Interpretability

Merupakan proyek klasifikasi biner klasik yang bertujuan untuk memprediksi peluang keselamatan penumpang kapal Titanic. Proyek ini memberikan penekanan khusus pada perbandingan interpretasi fitur antara model parametrik (Logistic Regression) dan non-parametrik (Random Forest), serta bagaimana ketergantungan antar variabel mempengaruhi keputusan model.

Poin Utama Proyek:

- Analisis Magnitudo Koefisien Regresi: Menggunakan besaran nilai absolut dari koefisien model Logistic Regression untuk menentukan pengaruh setiap fitur terhadap probabilitas keselamatan. Pendekatan ini memungkinkan kita melihat bobot matematis yang diberikan pada variabel seperti jenis kelamin, kelas penumpang, dan tarif (fare).
- Komparasi Interpretasi Antar Model: Menemukan wawasan kritis bahwa meskipun dua model (Logistic Regression dan Random Forest) menghasilkan akurasi yang hampir identik, fitur yang dianggap "penting" oleh masing-masing model bisa sangat berbeda. Hal ini menunjukkan bahwa cara algoritma memproses informasi (linier vs. berbasis pohon) sangat menentukan struktur logika prediksi.

- Identifikasi Multikolinieritas dan Ketergantungan Fitur: Menyoroti adanya dependensi antar variabel, terutama pada kategori seperti `who_man`, `who_woman`, dan `who_child`. Proyek ini menunjukkan bahwa informasi yang tumpang tindih dapat membingungkan estimasi kepentingan fitur jika tidak ditangani melalui analisis korelasi yang mendalam.
- Evaluasi Skor Akhir dan Akurasi: Mengukur performa model menggunakan akurasi pada test set yang belum pernah dilihat sebelumnya. Hasil yang konsisten menunjukkan bahwa model telah berhasil mempelajari pola umum dari tragedi Titanic daripada sekadar menghafal data latih.
- Sintesis Metodologi Menuju Proyek Final: Menyimpulkan bahwa memahami "mengapa" sebuah model memberikan prediksi tertentu jauh lebih penting daripada sekadar mengejar angka akurasi. Proyek ini membekali Anda dengan kerangka berpikir kritis untuk mempertanyakan validitas fitur sebelum menarik kesimpulan akhir dalam analisis data yang lebih kompleks.

2. Final Project: Rainfall Prediction Classifier & Model Optimization

Proyek ini merupakan implementasi end-to-end untuk memprediksi kejadian hujan menggunakan dataset cuaca dunia nyata. Fokus utamanya adalah membangun pipeline yang fleksibel, melakukan optimasi hyperparameter secara otomatis, dan membandingkan performa antara algoritma berbasis pohon dan regresi linier.

Poin Utama Proyek:

- Rekayasa Fitur & Preprocessing: Melakukan eksplorasi data untuk menangani nilai yang hilang, melakukan standarisasi pada fitur numerik, dan mengonversi variabel kategorikal menjadi format yang dapat diproses oleh model. Tahap ini memastikan data bersih sebelum masuk ke tahap pelatihan.
- Otomatisasi Pipeline & Alur Kerja: Membangun arsitektur Pipeline yang memungkinkan transisi mulus antara berbagai algoritma. Hal ini memungkinkan penggantian model (dari Random Forest ke Logistic Regression) hanya dengan memperbarui parameter estimator tanpa mengubah struktur kode utama.
- Optimasi dengan GridSearchCV: Menggunakan pencarian grid sistematis untuk menemukan parameter terbaik. Pada model Logistic Regression, fokus diberikan pada pemilihan penalti ($L1$ vs $L2$) dan penyesuaian bobot kelas (class weight) untuk menangani potensi ketidakseimbangan data pada hari-hari hujan.
- Analisis Komparatif Performa: Mengevaluasi hasil melalui `classification_report` dan Confusion Matrix. Perbandingan ini krusial untuk melihat apakah model

berbasis pohon yang kompleks memberikan peningkatan akurasi yang signifikan dibandingkan model regresi linier yang lebih sederhana dan cepat.

- Wawasan Strategis dalam Pemodelan: Menyadari bahwa performa model dapat ditingkatkan bukan hanya melalui algoritma, tetapi juga melalui teknik lanjutan seperti analisis klaster untuk rekayasa fitur baru atau proyeksi dimensi untuk mengurangi noise.

3. Final Project: Building a Rainfall Prediction Classifier

- Pertanyaan 1 (Upload - 10 Poin): Pastikan file yang Anda unggah adalah versi terbaru dari Jupyter Notebook Anda dalam format .ipynb. Jangan gunakan opsi GitHub; cukup seret dan lepaskan (drag and drop) file yang sudah Anda simpan setelah menyelesaikan Exercise 15.
- Pertanyaan 4 (Text Response - 2 Poin): Ini kemungkinan besar berkaitan dengan poin perbandingan antara Logistic Regression dan Random Forest yang kita bahas sebelumnya. Gunakan poin-poin berikut sebagai referensi jawaban Anda:
 - Akurasi: Bandingkan persentase akhir (misal: "Random Forest mencapai 85%, sementara Logistic Regression 83%").
 - True Positive Rate: Tekankan pada kemampuan model mendeteksi hujan yang sebenarnya (Recall).
 - Correct Predictions: Sebutkan jumlah total prediksi yang benar dari confusion matrix.
- Pertanyaan Lainnya (Multiple Choice/Select): Fokuslah pada konsep Data Leakage (seperti pentingnya melakukan fit StandardScaler hanya pada train set) dan interpretasi Confusion Matrix yang telah Anda pelajari di lab evaluasi.

COURSE 10

Module 1

1. Project Phase 1: SpaceX Data Collection & API Integration

Fase ini berfokus pada ekstraksi data dari API SpaceX untuk membangun dataset yang akan digunakan untuk memprediksi keberhasilan pendaratan tahap pertama roket Falcon 9. Kemampuan untuk menggunakan kembali (reusable) tahap pertama ini adalah kunci penghematan biaya SpaceX (62 juta USD vs 165 juta USD).

Poin Utama Lab:

- Ekstraksi Data API Multilevel: Anda berhasil melakukan permintaan GET ke API SpaceX. Karena data awal hanya berisi ID (seperti ID roket atau ID launchpad), Anda mengimplementasikan fungsi pembantu (helper functions) seperti `getBoosterVersion`, `getLaunchSite`, dan `getPayloadData` untuk melakukan panggilan API sekunder guna mendapatkan detail nama, koordinat, dan spesifikasi teknis.
- Transformasi JSON ke Dataframe: Menggunakan `pd.json_normalize()` untuk mengubah respon JSON yang kompleks dan bersarang menjadi struktur tabel Pandas yang bersih. Anda juga melakukan pembersihan awal dengan memfilter peluncuran yang memiliki satu core dan satu payload untuk menjaga konsistensi analisis.
- Normalisasi Data & Pembersihan: Melakukan konversi tipe data pada kolom tanggal menggunakan `pd.to_datetime` dan membatasi rentang waktu peluncuran hingga 13 November 2020. Anda juga memfilter dataset untuk hanya menyertakan Falcon 9, menyingkirkan varian Falcon 1 yang sudah tidak relevan untuk tujuan prediksi ini.
- Penanganan Missing Values (Data Wrangling): Mengidentifikasi nilai yang hilang pada kolom `PayloadMass`. Anda menerapkan strategi imputasi statistik dengan menghitung nilai rata-rata (mean) dan menggantikan `np.nan` dengan nilai tersebut, memastikan integritas data untuk pemodelan di masa depan.
- Persiapan Dataset Part 1: Menghasilkan file `dataset_part_1.csv` yang berisi fitur-fitur kritis seperti Orbit, Launch Site, Payload Mass, dan Outcome pendaratan. Kolom `FlightNumber` juga telah direset untuk mencerminkan urutan peluncuran Falcon 9 secara akurat.

2. Project Phase 2: Web Scraping & HTML Parsing

Fase ini berfokus pada teknik pengambilan data historis peluncuran Falcon 9 dan Falcon Heavy dari Wikipedia. Web scraping menjadi sangat penting ketika data yang kita butuhkan tidak tersedia secara rapi melalui API resmi.

Poin Utama Lab:

- Parsing HTML dengan BeautifulSoup: Anda berhasil melakukan permintaan HTTP GET ke snapshot Wikipedia tahun 2021 dan memproses konten HTML-nya. Anda menggunakan objek BeautifulSoup untuk menavigasi struktur dokumen, mencari tabel peluncuran (`wikitable`), dan mengisolasi elemen header (`th`) serta sel data (`td`).

- **Rekayasa Fungsi Pembantu (Helper Functions):** Karena data di Wikipedia mengandung banyak "noise" (seperti simbol referensi [1], spasi yang tidak konsisten, dan pembersihan unit), Anda memanfaatkan fungsi khusus seperti `get_mass` untuk membersihkan unit "kg" dan `extract_column_from_header` untuk mendapatkan nama kolom yang bersih tanpa karakter sisa.
- **Ekstraksi Data Iteratif:** Anda mengimplementasikan logika looping yang kompleks untuk menyisir setiap baris (tr) di berbagai tabel peluncuran. Anda berhasil memisahkan informasi krusial seperti nomor penerbangan, tanggal, waktu, versi booster, lokasi peluncuran, muatan (payload), massa muatan, orbit, pelanggan, hingga hasil akhir pendaratan booster.
- **Transformasi ke Struktur Pandas:** Setelah mengumpulkan ribuan poin data ke dalam `launch_dict`, Anda mengonversinya menjadi Pandas DataFrame. Anda juga menangani inkonsistensi panjang list dengan menggunakan `pd.Series(value)` untuk memastikan DataFrame tetap terbentuk meskipun ada baris yang memiliki data tidak lengkap.
- **Ekspor Data untuk Konsistensi:** Menghasilkan file `spacex_web_scraped.csv`. Data hasil scraping ini melengkapi data API dari lab sebelumnya, memberikan pandangan yang lebih luas mengenai sejarah peluncuran SpaceX untuk memperkuat model prediksi pendaratan Anda.

3. Project Phase 3: Data Wrangling & Binary Classification Labeling

Fase ini berfokus pada analisis hasil misi dan pembuatan label pelatihan (Training Labels). Anda melakukan transformasi dari data kualitatif mengenai hasil pendaratan menjadi data kuantitatif yang mendefinisikan sukses (1) atau gagal (0).

Poin Utama Lab:

- **Analisis Distribusi Launch Site & Orbit:** Menggunakan `value_counts()` untuk memahami persebaran peluncuran. Anda mengidentifikasi lokasi peluncuran utama seperti CCAFS SLC 40, KSC LC 39A, dan VAFB SLC 4E, serta memahami berbagai jenis orbit (LEO, GTO, SSO, dll.) yang menjadi tujuan misi.
- **Klasifikasi Hasil Pendaratan (Landing Outcomes):** Anda membedah berbagai skenario pendaratan yang ada dalam kolom Outcome. Anda mengkategorikan hasil pendaratan menjadi dua kelompok besar:
 - **Success (1):** Termasuk True Ocean, True RTLS (pendaratan di darat), dan True ASDS (pendaratan di kapal otonom/drone ship).

- Failure (0): Termasuk False Ocean, False RTLS, False ASDS, serta kategori None ASDS dan None None yang menunjukkan kegagalan total atau pendaratan yang tidak direncanakan.
- Pembuatan Label Class: Anda mengimplementasikan logika penentuan label menggunakan list comprehension atau fungsi pemetaan. Variabel `landing_class` ini menjadi variabel dependen (Y) dalam model klasifikasi Anda nantinya.
- Perhitungan Success Rate: Dengan menghitung rata-rata dari kolom Class (`df['Class'].mean()`), Anda mendapatkan metrik awal mengenai tingkat keberhasilan pendaratan SpaceX. Angka ini memberikan baseline performa sebelum melakukan analisis prediktif yang lebih dalam.
- Ekspor Dataset Part 2: Dataset hasil wrangling disimpan sebagai `dataset_part_2.csv`. File ini sekarang memiliki fitur yang lebih bersih dan label target yang siap digunakan untuk tahap analisis eksploratif (EDA) menggunakan visualisasi.

Module 2

1. Advanced SQL Data Extraction: SpaceX Insights

Fase ini berfokus pada penggunaan fungsi agregat, manipulasi string untuk data temporal, dan kueri bersarang (subqueries) untuk menjawab pertanyaan analitis yang kompleks.

Analisis Tugas & Implementasi Kueri:

- Task 8: Identifikasi Efisiensi Maksimal (Subqueries)
Anda berhasil mengidentifikasi semua versi booster yang membawa beban kerja maksimal. Dengan menggunakan subquery `SELECT MAX(...)`, Anda memastikan model pencarian bersifat dinamis—jika ada data baru dengan beban lebih tinggi, kueri ini akan tetap akurat.
 - Kueri: `SELECT "Booster_Version" FROM SPACEXTABLE WHERE "PAYLOAD_MASS_KG_" = (SELECT MAX("PAYLOAD_MASS_KG_") FROM SPACEXTABLE);`
- Task 9: Analisis Kegagalan Spesifik (String Manipulation)
Karena batasan SQLite pada nama bulan, Anda menggunakan fungsi `substr()` secara cerdas untuk membedah kolom tanggal. Kueri ini mengisolasi kegagalan pendaratan di drone ship secara spesifik pada tahun 2015, memberikan data historis penting untuk fase awal pengembangan pendaratan laut.

- Kueri: `SELECT substr("Date", 6, 2) AS Month, "Landing_Outcome", "Booster_Version", "Launch_Site" FROM SPACEXTABLE WHERE "Landing_Outcome" = 'Failure (drone ship)' AND substr("Date", 1, 4) = '2015';`
- Task 10: Pemeringkatan Hasil Pendaratan (Ranking & Aggregation)
Anda merangkum seluruh hasil misi dalam rentang waktu krusial (2010–2017). Penggunaan GROUP BY yang dikombinasikan dengan ORDER BY DESC memberikan pandangan hierarkis mengenai outcome yang paling sering terjadi, membantu manajemen melihat rasio keberhasilan terhadap kegagalan secara cepat.
 - Kueri: `SELECT "Landing_Outcome", COUNT(*) AS Outcome_Count FROM SPACEXTABLE WHERE "Date" BETWEEN '2010-06-04' AND '2017-03-20' GROUP BY "Landing_Outcome" ORDER BY Outcome_Count DESC;`

2. Feature Engineering & Data Transformation

Fase ini berfokus pada persiapan matriks fitur (X) sebelum masuk ke tahap pemodelan klasifikasi. Anda telah melakukan transformasi pada variabel kategorikal agar model matematika dapat memahami hubungan antar fitur.

Poin Utama Lab:

- Seleksi Fitur Strategis: Anda telah memilih variabel kunci yang memiliki pengaruh signifikan terhadap keberhasilan pendaratan, seperti PayloadMass (beban), Orbit (lintasan), LaunchSite (lokasi), serta aspek teknis seperti GridFins, Reused, dan Legs.
- Implementasi One-Hot Encoding (TASK 7): Karena kolom seperti Orbit, LaunchSite, LandingPad, dan Serial bersifat kategorikal (teks), Anda menggunakan fungsi `pd.get_dummies()`. Teknik ini menciptakan kolom biner baru untuk setiap kategori unik, memastikan model tidak mengasumsikan adanya urutan numerik pada data kategori.
 - Hasil: Dataset berkembang dari beberapa kolom menjadi banyak kolom biner yang mewakili setiap identitas unik (khususnya untuk ID Serial roket).
- Standardisasi Tipe Data (TASK 8): Untuk menjaga konsistensi komputasi pada algoritma seperti SVM atau KNN, Anda melakukan casting seluruh dataframe ke

tipe data float64 menggunakan fungsi `.astype()`. Hal ini memastikan semua nilai (baik biner 0/1 maupun numerik kontinu) berada dalam format presisi yang seragam.

- Persiapan Dataset Part 3: Data yang telah ditransformasi diekspor ke dalam `dataset_part_3.csv`. File ini merupakan Final Feature Set yang akan langsung diumpankan ke dalam model klasifikasi di modul berikutnya.

Module 3

1. Hands-on Lab: Interactive Visual Analytics with Folium

Fase ini berfokus pada Analisis Data Geospasial untuk memahami alasan strategis di balik pemilihan lokasi peluncuran SpaceX. Dengan menggunakan pustaka Folium, kamu beralih dari angka-angka di tabel ke visualisasi peta interaktif.

Poin Utama Lab:

- Visualisasi Lokasi Peluncuran: Menandai koordinat geografis setiap situs peluncuran (CCAFS SLC-40, KSC LC-39A, VAFB SLC-4E) menggunakan penanda peta (Markers) dan lingkaran (Circles).
- Analisis Proksimitas (Kedekatan): Mengukur jarak antara lokasi peluncuran dengan titik-titik infrastruktur penting menggunakan koordinat garis lintang dan bujur.
- Temuan Strategis:
 - Garis Pantai: Lokasi peluncuran berada di tepi laut untuk meminimalkan risiko jatuhnya puing ke pemukiman dan memudahkan pendaratan di Drone Ship.
 - Infrastruktur (Kereta & Jalan Raya): Kedekatan dengan jalur kereta api sangat krusial untuk logistik pengangkutan komponen roket yang berat.
 - Keamanan Publik: Situs peluncuran ditempatkan jauh dari pusat kota besar untuk mitigasi risiko ledakan dan dampak polusi suara.
- Fitur Interaktif: Menambahkan elemen seperti penanda jarak dinamis dan garis polylines untuk memvisualisasikan hubungan spasial secara langsung di peta.

2. Hands-on Lab: Build an Interactive Dashboard with Plotly Dash

Fase ini berfokus pada pembuatan alat visualisasi dinamis yang memungkinkan pemangku kepentingan untuk mengeksplorasi data peluncuran SpaceX secara mandiri melalui browser.

Poin Utama Lab:

- Arsitektur Dashboard: Menggunakan kerangka kerja Dash (berbasis Flask, Plotly.js, dan React.js) untuk membangun antarmuka pengguna tanpa perlu menulis kode JavaScript yang kompleks.
- Komponen Input Interaktif:
 - TASK 1 (Dropdown): Membuat menu pilihan situs peluncuran (CCAFS, KSC, VAFB) yang memungkinkan pengguna menyaring data secara global atau spesifik per lokasi.
 - TASK 3 (Range Slider): Mengimplementasikan slider untuk menyaring rentang Payload Mass (0 hingga 10.000 kg), memudahkan analisis korelasi antara berat muatan dan keberhasilan misi.
- Fungsi Callback Dinamis:
 - TASK 2 (Pie Chart): Mengembangkan logika Python untuk memperbarui bagan pai secara otomatis. Jika "All Sites" dipilih, bagan menunjukkan total keberhasilan antar situs; jika situs tertentu dipilih, bagan menunjukkan rasio sukses vs gagal untuk situs tersebut.
 - TASK 4 (Scatter Plot): Menghasilkan plot sebar yang memetakan Payload Mass terhadap Outcome (Class), dengan pewarnaan berdasarkan kategori versi Booster (v1.0, v1.1, FT, B4, B5).
- Analisis Data Real-Time: Dashboard ini memungkinkan identifikasi cepat terhadap tren teknis, seperti versi booster mana yang paling andal dan rentang muatan mana yang memiliki risiko kegagalan tertinggi.

Module 4

1. Hands-on Lab: Machine Learning Prediction Fase ini berfokus pada pembangunan, pelatihan, dan evaluasi berbagai model klasifikasi untuk memprediksi keberhasilan pendaratan tahap pertama Falcon 9. Anda menerapkan alur kerja Machine Learning profesional untuk menentukan algoritma mana yang paling andal bagi SpaceX.

Poin Utama Lab:

- Standardisasi Data (TASK 2): Anda menerapkan StandardScaler pada fitur-fitur (X) agar semua variabel memiliki skala yang seragam (rata-rata 0 dan varians 1). Ini sangat penting untuk algoritma berbasis jarak seperti KNN dan SVM agar tidak ada satu fitur pun yang mendominasi perhitungan hanya karena besaran angkanya.

- Pembagian Data & Validasi Silang (TASK 3): Menggunakan `train_test_split` dengan `test_size=0.2`. Dataset dibagi menjadi data latih dan data uji (18 sampel). Anda juga menggunakan Cross-Validation (`cv=10`) dalam pencarian hyperparameter untuk memastikan model tidak overfitting pada subset data tertentu.
- Optimasi Hyperparameter dengan `GridSearchCV`: Anda melatih empat algoritma berbeda dan mencari konfigurasi parameter terbaik untuk masing-masing:
 - Logistic Regression: Mencari nilai `C` (regulasi) yang optimal.
 - SVM (Support Vector Machine): Mencari kernel dan nilai penalti terbaik.
 - Decision Tree: Mencari kedalaman pohon dan kriteria split yang paling efisien.
 - KNN (K-Nearest Neighbors): Menentukan jumlah tetangga (`$k$`) yang paling akurat.
- Evaluasi melalui Confusion Matrix: Visualisasi ini memungkinkan Anda melihat distribusi True Positives dan False Positives. Pada lab ini, ditemukan bahwa model cukup akurat, namun terkadang masih menghasilkan False Positives (memprediksi pendaratan sukses padahal kenyataannya gagal).
- Penentuan Model Terbaik (TASK 12): Setelah membandingkan skor akurasi pada data uji, Anda menemukan bahwa keempat model (LogReg, SVM, Tree, dan KNN) memberikan performa yang sangat mirip (identik) pada dataset yang kecil ini.

Module 5 (membuat PPT)

1. Data Science Capstone Project: SpaceX Falcon 9. Ini adalah saatnya menyatukan semua kerja kerasmu dari lab-lab sebelumnya ke dalam satu dokumen presentasi profesional.

Struktur Presentasi: Data Science Capstone Project Report

- Komponen Dasar (Poin 1.1 - 1.4)
 - GitHub URL: Pastikan tautan repositori GitHub kamu aktif dan berisi semua file `.ipynb` dan dataset.
 - Executive Summary: Ringkas metode (API, Scraping, EDA, ML) dan hasil kunci (model terbaik, situs peluncuran paling sukses).

- Introduction: Jelaskan latar belakang SpaceX, biaya peluncuran (\$62M vs \$165M), dan rumusan masalah: memprediksi keberhasilan pendaratan tahap pertama.
- Data Methodology (Poin 1.5 - 1.7)
 - Data Collection (API): Jelaskan penggunaan API SpaceX, fungsi helper (getBoosterVersion, dll), dan tunjukkan alur datanya.
 - Data Collection (Web Scraping): Jelaskan penggunaan BeautifulSoup untuk mengambil data dari Wikipedia.
 - Data Wrangling: Jelaskan cara kamu membuat label biner (1 untuk sukses, 0 untuk gagal) dan menangani missing values.
- Exploratory Data Analysis / EDA (Poin 1.8 - 1.12)
 - Visualisasi (Python/Seaborn): Tampilkan grafik hubungan Payload vs. Launch Site dan tren keberhasilan tahunan.
 - SQL Analysis: Tampilkan kueri kunci (seperti Task 8-10) yang menunjukkan analisis payload maksimum dan peringkat outcome pendaratan.
- Interactive Analytics (Poin 1.10, 1.13, 1.14)
 - Folium Map: Masukkan tangkapan layar peta dengan penanda lokasi peluncuran dan analisis jarak (proksimitas) terhadap garis pantai/jalur kereta.
 - Plotly Dash: Masukkan tangkapan layar dashboard interaktifmu yang menunjukkan Pie Chart dan Scatter Plot dengan filter Payload Range.
- Predictive Analysis & Conclusion (Poin 1.15)
 - Machine Learning: Tampilkan tabel perbandingan akurasi model (LogReg, SVM, Tree, KNN).
 - Confusion Matrix: Tampilkan matriks untuk model terbaik.
 - Conclusion: Berikan kesimpulan cerdas, misalnya: "Meskipun semua model memiliki akurasi serupa (~83%), Decision Tree menawarkan kemudahan interpretasi fitur untuk pengambilan keputusan bisnis cepat."

COURSE 11

Module 1

1. Hands-on Lab: Generative AI for Data Preparation

Fase ini berfokus pada penggunaan prompt engineering untuk menghasilkan kode Python yang akurat guna membersihkan dan menyiapkan dataset (dalam kasus ini, dataset harga laptop).

Poin Utama Lab:

- Otomasi Impor Data: Menggunakan GenAI untuk membuat skrip pembacaan CSV yang bersih dengan asumsi baris pertama sebagai header.
 - Penanganan Missing Values (Data Cleaning):
 - Mengidentifikasi kolom yang memiliki data kosong dan menghitung jumlahnya.
 - Menerapkan aturan imputasi otomatis: Mode (nilai tersering) untuk data kategorikal (Screen_Size_cm) dan Mean (rata-rata) untuk data kontinu (Weight_kg).
 - Transformasi Tipe Data: Memastikan kolom numerik memiliki tipe data float agar dapat diproses dalam perhitungan statistik.
 - Standardisasi & Konversi Unit: * Mengonversi satuan dari sistem Metrik ke Imperial (Centimeter ke Inci, Kilogram ke Pon) tanpa perlu menghafal rumus konversi, karena GenAI sudah memilikinya dalam basis pengetahuannya.
 - Mengubah nama kolom secara otomatis untuk mencerminkan unit baru.
 - Normalisasi Data: Menerapkan normalisasi terhadap nilai maksimum pada kolom CPU_frequency untuk membawa data ke skala 0 hingga 1.
 - Rekayasa Fitur (Categorical to Numerical): Menggunakan teknik One-Hot Encoding melalui pd.get_dummies() untuk mengubah data teks (Screen) menjadi variabel indikator numerik (0 dan 1) agar siap digunakan dalam model prediktif.
2. Hands-on Lab: Generative AI for Querying Databases

Fase ini berfokus pada Prompt Engineering khusus untuk database. Kunci utamanya adalah memberikan "konteks" berupa deskripsi skema tabel agar AI dapat menghasilkan kueri yang akurat dan siap pakai.

Poin Utama Lab:

- Pentingnya Konteks: Memberikan rincian atribut (seperti age, gender, cp, num) ke dalam instruksi prompt memungkinkan AI memahami tipe data dan nilai kategorikal di balik angka (misal: 1 = male, 0 = female).
- Otomasi Kueri Agregasi: Menghasilkan fungsi statistik seperti MIN(), MAX(), dan AVG() untuk analisis demografi pasien dengan cepat.

- Transformasi Data melalui Kueri: Menggunakan pernyataan CASE WHEN untuk mengubah kode angka (1, 2, 3, 4) menjadi label teks yang bermakna (seperti typical angina) langsung dalam hasil kueri.
- Analisis Segmentasi (Binning): Membuat pengelompokan rentang usia (misal: 20-29, 30-39) menggunakan logika SQL untuk melihat tren distribusi penyakit jantung pada kelompok umur yang berbeda.

Module 2

1. Hands-on Lab: Generative AI for Data Insights

Fase ini berfokus pada penggunaan AI untuk menghasilkan kode analisis data yang kompleks. Anda belajar bagaimana mengarahkan AI untuk melakukan visualisasi dan uji statistik guna memahami faktor-faktor yang mempengaruhi harga laptop.

Poin Utama Lab:

- Deskripsi Statistik Holistik: Menggunakan GenAI untuk menghasilkan skrip `describe(include='all')`. Ini memungkinkan Anda melihat gambaran besar data, termasuk rata-rata, standar deviasi untuk data numerik, serta nilai unik dan frekuensi untuk data kategorikal (object).
- Visualisasi Distribusi Parameter:
 - Regression Plots: Digunakan untuk atribut kontinu (CPU_frequency, Weight) guna melihat tren hubungan linier terhadap harga.
 - Box Plots: Digunakan untuk atribut kategorikal (Category, OS, RAM) guna melihat sebaran harga dan mendeteksi adanya outlier pada kelompok tertentu.
- Evaluasi Dependensi (Uji Statistik):
 - Menerapkan kode untuk menghitung Koefisien Pearson (kekuatan korelasi) dan P-value (signifikansi statistik).
 - Data Scientist menggunakan metrik ini untuk menentukan fitur mana yang paling berpengaruh sebelum dimasukkan ke dalam model prediksi.
- Analisis Grup & Pivot:
 - Mengelompokkan data berdasarkan kombinasi fitur (misal: GPU dan CPU_core).
 - Menciptakan Pivot Table untuk melihat rata-rata harga pada berbagai segmen spesifikasi.

- Memvisualisasikan matriks tersebut menggunakan pcolor plot (Heatmap), memudahkan identifikasi segmen "premium" atau "ekonomis" secara visual.

2. Interactive Data Visualization Agent with LangChain

Fase ini berfokus pada penggunaan LangChain dan LLM (Llama 3) untuk menciptakan antarmuka percakapan yang mampu melakukan analisis visual pada dataset pendidikan siswa (Student Performance Dataset).

Poin Utama Lab:

- `create_pandas_dataframe_agent`: Anda menggunakan fungsi khusus dari LangChain yang memberikan kemampuan kepada LLM untuk "melihat" struktur DataFrame Pandas, menulis kode Python yang relevan, dan menjalankannya untuk memberikan jawaban.
- Analisis Data via Bahasa Alami: Menghilangkan kebutuhan untuk menulis kode manual. Anda cukup memberikan perintah seperti "Berapa jumlah baris dalam file ini?" dan agen akan menjalankan `len(df)` di latar belakang.
- Visualisasi Dinamis:
 - Task 1 & 2: Membuat grafik batang untuk distribusi gender dan pie chart untuk konsumsi alkohol akhir pekan secara instan melalui perintah teks.
 - Task 3 & 4: Melakukan analisis korelasi kompleks, seperti hubungan antara waktu luang (freetime) dengan nilai akhir (G3) menggunakan box plots, atau pengaruh pendidikan orang tua terhadap prestasi anak.
- Transparansi Kode (Intermediate Steps): Anda belajar cara mengintip "pemikiran" AI melalui `intermediate_steps`. Ini penting untuk memvalidasi apakah logika Python yang digunakan AI sudah benar dan akurat.

3. Hands-on Lab: Generative AI for Models Development

Fase ini berfokus pada penggunaan prompt engineering untuk menghasilkan kode machine learning yang dapat memprediksi harga laptop berdasarkan spesifikasinya. Anda belajar membangun model dari yang paling sederhana hingga yang paling canggih menggunakan teknik regularisasi.

Poin Utama Lab:

- Linear Regression (Satu & Banyak Variabel):
 - Menggunakan AI untuk memodelkan hubungan antara satu fitur (misal: `CPU_frequency`) terhadap Price.

- Mengembangkan model Multiple Linear Regression yang menggabungkan banyak fitur (RAM, Storage, GPU) untuk meningkatkan akurasi prediksi.
 - Polynomial Regression:
 - Memahami bahwa hubungan antar data tidak selalu garis lurus. Anda menggunakan AI untuk membuat fitur pangkat tinggi (derajat 2, 3, atau 5) guna menangkap pola data yang lebih kompleks.
 - Pipeline Development:
 - Membangun alur kerja otomatis yang menggabungkan StandardScaler (skalasi data), PolynomialFeatures, dan LinearRegression dalam satu urutan proses yang rapi menggunakan sklearn.pipeline.
 - Ridge Regression & Hyperparameter Tuning:
 - Menerapkan Ridge Regression untuk mencegah overfitting (model terlalu kaku pada data latih).
 - Menggunakan Grid Search dengan Cross-Validation untuk secara otomatis mencari nilai alpha terbaik yang menghasilkan error (MSE) terkecil.
4. Hands-on Lab: Considerations for Data Professionals using GenAI

Fase ini berfokus pada Etika dan Tata Kelola AI. Sebagai calon Data Scientist, Anda tidak hanya dituntut untuk membuat model yang akurat, tetapi juga model yang bertanggung jawab (Responsible AI).

Prinsip Utama yang Dipelajari:

- Tanggung Jawab & Akuntabilitas (Responsibility & Accountability):
 - Jika chatbot atau model memberikan respon yang tidak pantas, tim pengembang harus melakukan analisis akar masalah (root cause analysis).
 - Perlunya mekanisme Human-in-the-Loop, di mana manusia tetap melakukan pengawasan terhadap konten sensitif atau berbahaya yang dihasilkan AI.
- Keandalan Model (Reliability):
 - Exercise 3 (Product Descriptions): Mengatasi masalah informasi yang tidak akurat pada platform e-commerce.
 - Solusi melibatkan pengujian Quality Assurance (QA) yang ketat terhadap dataset yang beragam dan penggunaan sumber data yang bereputasi tinggi.
- Transparansi & Kejujuran:

- Perusahaan harus terbuka kepada pelanggan jika terjadi kesalahan pada AI dan menjelaskan langkah-langkah perbaikan yang sedang diambil.
- Iterasi Berkelanjutan:
 - Model AI tidak bersifat "sekali jadi". Diperlukan pembaruan berkala berdasarkan umpan balik pengguna (user feedback) untuk memperbaiki bias atau kesalahan informasi yang muncul setelah peluncuran.

Module 3

1. proyek akhir ini:

Fase 1: Persiapan Data (Cleaning)

Kunci utama di sini adalah memastikan AI memahami bahwa data memiliki nilai kosong (*missing*) dan duplikat.

Prompt Strategis:

"Write a Python code to read a CSV file from a URL into a pandas DataFrame. Then, identify columns with missing values and fill them with the mean of their respective columns. Finally, find and remove any duplicate rows and print the first 5 rows of the cleaned data."

Fase 2: Wawasan Data & Visualisasi (EDA)

Klien (Dealer Ford) memiliki permintaan spesifik untuk memahami perilaku pasar.

Analisis Korelasi: Cari 5 atribut paling berpengaruh terhadap price.

Fuel Type Count: Menghitung jumlah penjualan per jenis bahan bakar (*Petrol, Diesel, Hybrid, etc.*).

Transmission Outliers: Menggunakan **Seaborn Boxplot** untuk melihat apakah *Automatic, Manual*, atau *Semi-Auto* yang memiliki banyak harga "tidak wajar" (outliers).

Prompt Visualisasi:

"Write a Python code using Seaborn to: 1. Count and plot the number of cars for each 'fuelType'. 2. Create a box plot comparing 'transmission' types against 'price' to identify outliers. 3. Generate a regression plot between 'mpg' and 'price' to show their correlation."

Fase 3: Pengembangan Model (Regresi)

Anda akan membandingkan beberapa tingkat kompleksitas model untuk menemukan "quotation price" yang paling akurat.

Model	Fitur	Teknik
Simple Linear	mpg	Dasar perbandingan.
Multiple Linear	year, mileage, tax, mpg, engineSize	Menggunakan multi-fitur.
Pipeline	Fitur yang sama	Scaling + Polynomial (derajat 2) + Linear Regression.

Fase 4: Optimasi & Model Final (Ridge + Grid Search)

Ini adalah tahap profesional untuk memastikan model tidak *overfitting*.

Ridge Regression: Menggunakan parameter $\alpha=0.1$.

Grid Search: Mencari α terbaik dari pilihan {0.01, 0.1, 1, 10, 100} dengan **4-fold cross-validation**.

Prompt Optimasi:

"Write a Python code to perform a Grid Search on a Ridge Regression model. Use second-order polynomial features from ['year', 'mileage', 'tax', 'mpg', 'engineSize']. Search for the best alpha among [0.01, 0.1, 1, 10, 100] using 4-fold cross-validation. Display the best alpha, R^2 , and MSE."